

Введение в математическую статистику

Содержание

1	Введение в математическую статистику. Первичная обработка данных	2
1.1	Вместо введения	2
1.2	Вариационный ряд	4
1.3	Эмпирическая функция распределения	5
2	Введение в теорию оценивания	7
2.1	Выборочные характеристики	7
2.2	Понятие оценки	8
2.3	Несмещенные оценки	9
2.4	Состоятельность оценки	11
3	Некоторые способы построения оценок	13
3.1	Метод моментов	13
3.2	Метод максимального правдоподобия	14
4	Сравнения различных оценок	16
4.1	Среднеквадратичный подход к сравнению оценок	16
4.2	Эффективные оценки. Неравенство Рао-Крамера.	20
4.3	О доказательстве регулярности модели	25
4.4	Экспоненциальное семейство	26
5	Условное математическое ожидание	28
6	Способы построения оценок	33
6.1	Достаточные статистики	33
6.2	Модели с выборочным пространством, зависящем от параметра θ	41

7	Асимптотические свойства оценки максимального правдоподобия.	44
8	Асимптотически доверительный интервал.	49
9	Проверка статистических гипотез	50
9.1	Основные понятия	50
9.2	Проверка гипотезы о виде распределения	54
9.2.1	Критерий согласия Колмогорова	55
9.2.2	Критерий согласия хи-квадрат	58
9.3	Гипотеза и критерии однородности	63
9.3.1	Критерий однородности Смирнова	63
9.3.2	Критерий однородности хи-квадрат	64
9.4	Выбор из двух простых гипотез. Критерий Неймана-Пирсона .	65
10	Сложные гипотезы	74
	Литература	76

1 Введение в математическую статистику.

Первичная обработка данных

1.1 Вместо введения

Математическая статистика является направлением в математике, исследующим способы обработки, представления, систематизации данных для получения практических выводов.

Математическая статистика тесно связана с теорией вероятности, в виду того, что использует аналогичные методы и приемы рассуждений. В то же время, задачи математической статистики в некотором смысле являются двойственными к задачам теории вероятностей.

В теории вероятностей с использованием понятий случайных событий и случайных величин определяется модель явления и исследуются его свойства. В математической статистике известны реализации некоторых случайных величин, которые называются *статистическими данными*, и определяются как совокупность числовых (как правило) или качественных характеристик, порожденных некоторым источником.

Математическую статистику можно определить как раздел математики, в котором для математических моделей процессов порождения статистических данных изучаются методы систематизации, обработки, методы использования результатов для научных и (или) практических выводов.

Данный курс представляет собой лишь введение в математическую статистику и рассматривает следующие задачи:

- оценивание неизвестных параметров распределений;
- проверка статистических гипотез о виде распределения;
- прогнозирование.

Введем основные понятия математической статистики: наблюдение, выборка, реализация выборки.

Определение 1.1. *Наблюдение — это значение, которое приняла случайная величина.*

Определение 1.2. *Выборкой будем называть случайный вектор $X = (X_1, \dots, X_n)$, компонентами которого являются наблюдаемые случайные величины.*

Будем говорить, что выборка X из распределения ξ (или $\mathcal{L}(\xi)$), если компоненты вектора X есть независимые, одинаково распределенные случайные величины, имеющие такое же распределение, как и случайная величина ξ .

Определение 1.3. *Реализацией выборки будем называть набор из n наблюдений $x = (x_1, \dots, x_n)$.*

Можно рассматривать реализацию выборки как наблюдение за выборкой.

Определение 1.4. *Выборочным пространством будем называть множество всех возможных значений реализаций выборки вместе с σ -алгеброй измеримых подмножеств этого пространства.*

В теории вероятностей каждая случайная величина $\eta : \Omega \rightarrow B$, определенная на вероятностном пространстве (Ω, \mathcal{F}, P) порождает на пространстве (B, \mathcal{B}) вероятностные меры $P_\eta = P(\eta \in C)$, $C \in \mathcal{B}$, определяемые функцией распределения F_η . В математической статистике в большинстве случаев на выборочном пространстве определяется не одна мера, а конечное или бесконечное семейство вероятностных мер.

Определение 1.5. Семейством вероятностных мер (или параметрическим семейством), заданных на пространстве (B, \mathcal{B}) будем называть множество $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$, где Θ — некоторое множество параметров.

Наверное самым часто используемым понятием (после выборки) в курсе будет понятие статистики.

Определение 1.6. Статистикой будем называть произвольное отображение

$$T(X) = (T_1(X), \dots, T_l(X)) : \Omega^n \rightarrow \mathbb{R}^l,$$

где $T_i(X) : \Omega^n \rightarrow \mathbb{R}$ — произвольное измеримое отображение.

1.2 Вариационный ряд

Рассмотрим выборку $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$, а $x = (x_1, \dots, x_n)$ — реализация этой выборки. Вектору x можно поставить в соответствие упорядоченную последовательность:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}, \text{ где}$$

$$x_{(1)} = \min \{x_1, x_2, \dots, x_n\},$$

$$x_{(i)} = \min \{x_1, x_2, \dots, x_n\} \setminus \{x_{(1)}, \dots, x_{(i-1)}\},$$

$$x_{(n)} = \max \{x_1, x_2, \dots, x_n\}.$$

Обозначим через $X_{(i)}$ случайную величину, которая для каждой реализации выборки x принимает значение $x_{(i)}$.

Определение 1.7. Упорядоченную последовательность случайных величин $X_{(1)}, X_{(2)}, \dots, X_{(n)}$, полученную по выборке X будем называть вариационным рядом выборки, а сами значения $X_{(i)}$ — порядковыми статистиками. Значения $X_{(1)}$ и $X_{(n)}$ будем называть минимальными и максимальными значениями выборки, а величину $\rho = X_{(n)} - X_{(1)}$ будем называть размахом выборки.

Определение 1.8. Медианой выборки будем называть величину, равную $X_{(k+1)}$, если $n = 2k + 1$ и $\frac{1}{2} (X_{(k)} + X_{(k+1)})$, если $n = 2k$.

1.3 Эмпирическая функция распределения

Пусть имеется выборка $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$. Функцию распределения (теоретическую функцию распределения) случайной величины ξ будем обозначать $F(y)$.

Определение 1.9. Для каждого $y \in \mathbb{R}$ рассмотрим случайную величину

$$\mu_n(y) = \sum_{i=1}^n \text{Ind}(X_i \leq y),$$

равную числу элементов выборки X меньших или равных y . Функцию $\hat{F}_n(y) = \frac{\mu_n(y)}{n}$ будем называть эмпирической функцией распределения (э.ф.р.), соответствующей выборке X .

Заметим, что эмпирическая функция распределения является случайной величиной и принимает следующие значения:

$$\left\{ 0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n} \right\}.$$

При этом, используя равенство $\mathbf{P}(X_i \leq y) = F(y)$, легко показать, что $\hat{F}_n(x)$ принимает значение равное k/n с вероятностью:

$$\mathbf{P}\left(\hat{F}_n(x) = \frac{k}{n}\right) = \binom{n}{k} F^k(x) (1 - F(x))^{n-k}.$$

Заметим, что для каждой реализации выборки x функция $\hat{F}_n(x)$ однозначно определена и очевидным образом обладает следующими свойствами, присущими теоретическим функциям распределения:

- $0 \leq \hat{F}_n(x) \leq 1$,
- $\hat{F}_n(x)$ является не убывающей функцией,
- $\hat{F}_n(x)$ непрерывна справа.

Докажем теорему, показывающую, что для произвольного фиксированного $y \in \mathbb{R}$ э.ф.р. $\hat{F}_n(y)$ с увеличением объема выборки n стремиться к значению функции распределения $F(y)$.

Теорема 1.10. Для $\forall x \in \mathbb{R}$ и для $\forall \varepsilon > 0$ при $n \rightarrow \infty$

$$\mathbf{P}\left(\left|\hat{F}_n(x) - F(x)\right| < \varepsilon\right) \rightarrow 1$$

(то есть $\widehat{F}_n(x) \xrightarrow{P} F(x)$).

Доказательство. Введем обозначение для последовательности независимых, одинаково распределенных случайных величин $\eta_j = \text{Ind}(X_j \leq x)$, где $j = \overline{1, n}$. Тогда, $M \eta_j = P(\eta_j \leq x) = F(x)$, а $D \eta_j = F(x)(1 - F(x))$. Заметим, что

$$\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \eta_i$$

Тогда, согласно закону больших чисел:

$$\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \eta_i \xrightarrow{P} F(x)$$

□

Оценим скорость сближения э.ф.р. и теоретической функции распределения. Найдем математическое ожидание и дисперсию $\widehat{F}_n(y)$

$$M \widehat{F}_n(y) = M \frac{1}{n} \sum_{i=1}^n \eta_i = F(x),$$

$$D \widehat{F}_n(x) = D \frac{1}{n} \sum_{i=1}^n \eta_i = \frac{1}{n^2} \sum_{i=1}^n D \eta_i = \frac{1}{n} F(x)(1 - F(x)).$$

Используя неравенство Чебышева:

$$P(|\xi - M \xi| > \varepsilon) \leq \frac{D \xi}{\varepsilon^2}$$

получаем следующую оценку:

$$P\left(\sqrt{n} \left| \widehat{F}_n(x) - F(x) \right| > t\right) \leq \frac{F(x)(1 - F(x))}{t^2}.$$

Приведем без доказательства теорему, которую можно использовать для оценивания скорости сходимости выборочной функции распределения к её теоретическому аналогу.

Теорема 1.11 (Теорема Колмогорова). *Рассмотрим функцию*

$$D_n = D_n(X) = \sup \left| \widehat{F}_n(x) - F(x) \right|.$$

Если $F(x)$ – непрерывная функция распределения, то $\forall t > 0$:

$$\lim_{n \rightarrow \infty} P(\sqrt{n}D_n \leq t) = K(t) = \sum_{j=-\infty}^{\infty} (-1)^j \cdot e^{-2j^2 t^2}.$$

Статистику $K(t)$ называют распределением Колмогорова, которое не зависит от вида функции распределения.

Теорема Колмогорова дает асимптотическую оценку и использование статистики Колмогорова возможно при объеме выборки $n \geq 20$. Помимо предельного результата Колмогоров в работе [?] предложены рекуррентные соотношения для конечных n . На русском языке доказательство теоремы можно найти, например в [?].

Следующая теорема, которая также дается без доказательства, также дает важное представление о свойствах э.ф.р.

Теорема 1.12 (Теорема Смирнова). Пусть $\hat{F}_{1n}(x), \hat{F}_{2m}(x)$ – две эмпирические функции распределения построенные на двух независимых выборках n и m соответственно. И $D_{n,m} = \sup_{x \in \mathbb{R}} |\hat{F}_{1n}(x) - \hat{F}_{2m}(x)|$, а $F(x)$ – непрерывная функция распределения. $\forall t > 0$:

$$\lim_{n,m \rightarrow \infty} P\left(\sqrt{\frac{n \cdot m}{n+m}} D_{n,m} \leq t\right) = K(t).$$

2 Введение в теорию оценивания

2.1 Выборочные характеристики

Пусть имеется выборка $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$.

Определение 2.1. Выборочными характеристиками будем называть измеримые функционалы от эмпирического распределения (то есть функции от выборки).

Определение 2.2. Выборочным моментом порядка k называется величина

$$\hat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n X_i^k = \int_{-\infty}^{\infty} t^k d\hat{F}_n(t),$$

Иногда, для краткости, выборочный момент 1 порядка обозначают \bar{X} .

Определение 2.3. *Выборочным центральным моментом порядка k называется величина, определенная формулой:*

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\alpha}_1)^k = \int_{-\infty}^{\infty} (t - \hat{\alpha}_1)^k d\hat{F}_n(t)$$

Определение 2.4. $\hat{\alpha}_1$ будем называть выборочным средним, $\hat{\mu}_2$ будем называть выборочной дисперсией

2.2 Понятие оценки

Одним из направлений математической статистики является разработка «рациональных» методов оценивания неизвестных истинных значений характеристик наблюдаемых случайных величин. Понятие статистической оценки использовалось ранее (хоть и не называлось), когда говорилось, что значение э.ф.р. $\hat{F}_n(x)$ в каждой точке x можно рассматривать в качестве приближенного значения (оценки) для теоретической функции распределения (см. теорему 1.10). При этом, для выборок большого объема значительная разница между значениями выборочной и теоретической характеристиками маловероятна (см. теорему 1.11).

Оценка истинного значения g_0 некоторой характеристики $g = g(\xi)$ случайной величины ξ по выборке $X = (X_1, X_2, \dots, X_n)$ из параметрического семейства $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ подразумевает построение такой функции $T_n = T_n(X)$, значение которой t при наблюдавшейся в эксперименте реализации выборки является приближением (в некотором смысле) для g_0 . Нестрого можно написать, что $g_0 \approx t$. В этом случае говорят, что статистика T_n оценивает g или что T_n есть оценка для g и обозначают: $\hat{g} = T_n(X)$. Такая оценка называется *точечной оценкой*.

Приведем пример построения оценок. Пусть $x = (x_1, \dots, x_n)$ — реализация выборки из равномерного распределения $R(0, \theta]$. Очевидно, что следующие функции являются оценками на неизвестный параметр θ .

$$\hat{\theta}_1 = \left(\frac{1}{n} \sum_{j=1}^n x_j \right) \cdot 2,$$

$$\hat{\theta}_2 = x_{(n)} = \max\{x_1, \dots, x_n\}.$$

Эти оценки являются функциями от выборки и не зависят от θ . При $n \rightarrow \infty$ обе оценки «должны» должны приближаться к истинному значению θ .

2.3 Несмещенные оценки

Любая оценка $T = T(X)$, где T — измеримая функция, является случайной величиной. Для произвольной случайной величины определены понятия математического ожидания и дисперсии.

Рассмотрим параметрическую модель

$$\mathcal{F} = \{F_\theta, \theta \in \Theta\}$$

которое задает распределение вероятностей на выборочном пространстве.

Нижним индексом θ при символах математического ожидания будем обозначать то, что соответствующие величины вычисляются для распределения F_θ . Обозначим $\mathbf{M}_\theta T(X)$ и $\mathbf{D}_\theta T(X)$ соответственно математическое ожидание и дисперсию статистики T в случае, когда функция распределения реализации выборки $\bar{x} = (x_1, x_2, \dots, x_n)$ есть

$$F_{X,\theta}(X) = F_{\xi,\theta}(x_1) \cdot \dots \cdot F_{\xi,\theta}(x_n).$$

Математическое ожидание выписывается по определению:

$$\mathbf{M}_\theta(T(x)) = \int_B T(t) dF_\theta(t),$$

что в непрерывном случае соответствует формуле:

$$\int_{\mathbb{R}^n} T(t) f_\theta(x_1) \cdot \dots \cdot f_\theta(x_n) dx_1 \dots dx_n,$$

где $f(x)$ — плотность случайной величины ξ , и в дискретном случае соответствует:

$$\sum_{x \in B} T(t) p_\theta(x_1) \cdot \dots \cdot p_\theta(x_n),$$

где $p(x)$ соответствует значению вероятности $\mathbf{P}(\xi = x)$.

Определение 2.5. Статистика $T = T(X)$ называется несмещенной в среднем (или просто несмещенная) оценкой для заданной параметрической

функции $\tau(\theta)$, если она удовлетворяет условию

$$\mathbf{M}_\theta T(x) = \tau(\theta), \forall \theta \in \Theta,$$

которое называется уравнением несмещенности.

Определение 2.6. Смещением оценки $T(X)$ неизвестного параметра $\tau(\theta)$ будем называть величину

$$b(\theta) = \mathbf{M}_\theta T(X) - \tau(\theta).$$

Если смещение равно 0, то оценка несмещенная.

Найдем математическое ожидание выборочного среднего и выборочной дисперсии.

$$\mathbf{M}_\theta \hat{\alpha}_1 = \mathbf{M}_\theta \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n \mathbf{M}_\theta X_i = \mathbf{M}_\theta X_1 = \mathbf{M}_\theta \xi.$$

Получили, что выборочное среднее является несмещенной оценкой для математического ожидания случайной величины ξ .

Введем обозначение $Y_i = X_i - \alpha_1$, где $\alpha_1 = \mathbf{M} \xi$, и найдем математическое ожидание выборочной дисперсии. Для начала преобразуем выражение для выборочной дисперсии:

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \alpha_1 - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{n} \sum_{i=1}^n Y_i^2 - \bar{Y}^2.$$

Так как $\mathbf{M}_\theta Y_i = 0$, $\mathbf{M}_\theta Y_i^2 = \mu_2$, $\mathbf{M}_\theta Y_i Y_j = \mathbf{M}_\theta Y_i \mathbf{M}_\theta Y_j = 0$, где $\mu_2 = \mathbf{D} \xi$. Если $i \neq j$, верно следующее:

$$\mathbf{M} \bar{Y}^2 = \frac{1}{n^2} \sum_{i,j=1}^n \mathbf{M}_\theta Y_i Y_j = \frac{1}{n^2} \sum_{i=1}^n \mathbf{M}_\theta Y_i^2 = \frac{\mu_2}{n},$$

Так как

$$\frac{n\mu_2}{n} - \frac{\mu_2}{n} = \frac{n-1}{n} \mu_2,$$

при $n \rightarrow \infty$ значение выборочной дисперсии хоть и сходится к значению дисперсии случайной величины ξ , но является смещенной оценкой.

Можно построить несмещенную оценку дисперсии:

$$\hat{\mu}'_2 = \frac{n}{n-1} \hat{\mu}_2.$$

Пример 2.7. Несмещенные оценки не всегда существуют. Пусть $\xi \sim \text{Pois}(\theta)$. Покажем, что ни для одной функции $T = T(X)$ не будет выполнено равенство $\mathbf{M}_\theta T(X) = \theta^{-1}$. Предположим обратное:

$$\frac{1}{\theta} = \mathbf{M}_\theta T(X) = \sum_{k=0}^{\infty} T(k) \cdot \frac{\theta^k}{k!} \cdot e^{-\theta}.$$

Тогда будет верно равенство:

$$\sum_{k=0}^{\infty} T(k) \cdot \frac{\theta^{k+1}}{k!} = e^\theta = \sum_{r=0}^{\infty} \frac{\theta^r}{r!}, \forall \theta > 0.$$

Такой функции $T(x)$ не существует (можно показать устремив θ к 0).

2.4 Состоятельность оценки

Определение 2.8. Статистика $T_n = T_n(X)$ называется состоятельной оценкой для неизвестного параметра $\tau(\theta)$ случайной величины ξ , если при $n \rightarrow \infty$:

$$T_n(X) \xrightarrow[n \rightarrow \infty]{\mathbf{P}} \tau(\theta).$$

Утверждение 2.9. Пусть элементы выборки $X = (X_1, \dots, X_n)$ являются независимыми одинаково распределенными случайными величинами и $\mathbf{M}|X_1| < \infty$. Тогда при $n \rightarrow \infty$ выборочные моменты порядка k сходятся к k -ым моментам случайной величины X_1 :

$$\hat{\alpha}_k \xrightarrow{\mathbf{P}} \mathbf{M} X_1^k.$$

Доказательство. Рассмотрим статистику

$$S = S(X) = \int g(x) d\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n g(x_i).$$

Статистика S представляет собой сумму независимых одинаково распределенных случайных величин, при этом $\mathbf{M} g(X_1) = \int g(t) dF(t)$. По закону больших чисел:

$$S \xrightarrow{P} \mathbf{M} g(x_i),$$

что и заканчивает доказательство утверждения. \square

Верно и более сильное утверждение, что любая непрерывная функция от выборочных моментов сходится по вероятности к значению этой функции от соответствующих моментов случайной величины.

Теорема 2.10. Пусть случайные величины $\eta_1(n), \dots, \eta_k(n)$ сходятся по вероятности при $n \rightarrow \infty$ к некоторым константам c_1, \dots, c_k . Тогда для любой непрерывной функции $\varphi(x_1, \dots, x_k)$ случайная величина $\varphi(\eta_1(n), \dots, \eta_k(n))$ сходится по вероятности к $\varphi(c_1, \dots, c_k)$.

Доказательство. По условию теоремы φ — непрерывная функция. Тогда $\forall \varepsilon > 0 \exists \delta = \delta(\varepsilon)$:

$$|\varphi(x_1, \dots, x_k) - \varphi(c_1, \dots, c_k)| < \varepsilon \text{ при } |x_i - c_i| < \delta, \quad i = \overline{1, k}.$$

Пусть $B_i = \{|\eta_i(n) - c_i| < \delta\}$. Рассмотрим событие $B = B_1 \cdot \dots \cdot B_k$. Выполнение события B влечет за собой выполнение события

$$C = \{|\varphi(\eta_1(n), \dots, \eta_k(n)) - \varphi(c_1, \dots, c_k)| < \varepsilon\}.$$

Рассмотрим следующую последовательность неравенств:

$$\mathbf{P}(C) \geq \mathbf{P}(B) = 1 - \mathbf{P}(\overline{B}) = 1 - \mathbf{P}(\overline{B}_1 \cup \dots \cup \overline{B}_k) \geq 1 - \sum_{i=1}^k \mathbf{P}(\overline{B}_i).$$

Так как $\eta_i(n) \xrightarrow{P} c_i$, то для фиксированного δ для произвольного $\gamma > 0$ существует номер $n_i = n_i(\gamma)$ такой, что для всех $n \geq n_i$ выполняется

$$\mathbf{P}\{|\eta_i(n) - c_i| \geq \delta\} \leq \frac{\gamma}{k}.$$

Пусть $n_0 = \max\{n_1, \dots, n_k\}$. Тогда для любого $n \geq n_0$ верно неравенство: $\mathbf{P}(\overline{B}_i) < \frac{\gamma}{k}$ и

$$\mathbf{P}(C) \geq 1 - \gamma.$$

Отсюда и от произвольности выбора γ следует доказательство теоремы. \square

Заметим, что для проверки состоятельности несмещенной оценки T_n для неизвестного параметра $\tau(\theta)$ достаточно убедиться, что ее дисперсия стремится к 0 при $n \rightarrow \infty$. Действительно, по неравенству Чебышева

$$P(|T_n(X) - \tau(\theta)| \geq \varepsilon) \leq \frac{D_\theta T_n(X)}{\varepsilon} \rightarrow 0,$$

что говорит о сходимости по вероятности. Таким образом, легко показать, что значение э.ф.р. в произвольной точке y есть состоятельная оценка для функции распределения в точке y .

3 Некоторые способы построения оценок

3.1 Метод моментов

Пусть имеется выборка $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$, $\mathcal{L}(\xi) \in \mathcal{F} = \{F_\theta, \theta \in \Theta\}$, где $\theta = (\theta_1, \dots, \theta_r) \in \mathbb{R}^r$.

Рассмотрим один из простейших способов построения состоятельных оценок. Пусть у случайной величины ξ имеются первые r моментов, т.е. $\alpha_k = M_\theta(\xi^k) < \infty$, являющиеся функциями от неизвестного θ : $\alpha_k = \alpha_k(\theta)$, $k = \overline{1, r}$.

Рассмотрим следующую систему:

$$\left\{ \alpha_k(\theta) = \hat{\alpha}_k, k = \overline{1, r} \right.$$

в которой ровно r неизвестных $\theta_1, \dots, \theta_r$.

Пусть эта система однозначно разрешима и ее решением являются $\hat{\theta}_1, \dots, \hat{\theta}_r$, $\hat{\theta}_i = \phi_i(\hat{\alpha}_1, \dots, \hat{\alpha}_k)$, ϕ_i — некоторая функция.

Оценки $\hat{\theta}_i = \phi_i(\hat{\alpha}_1, \dots, \hat{\alpha}_k)$ будем называть оценками, построенными по методу моментов. Заметим, что если функция ϕ_i является непрерывной функцией, то по теореме 2.10 оценка $\hat{\theta}_i$ является состоятельной.

Заметим, что метод напрямую неприменим, когда выборочный момент не существует — $M_\theta(\xi^k) = \alpha^k = \infty$.

Пример 3.1. Рассмотрим выборку из распределения $\mathcal{L}(\xi) \sim N(\theta_1, \theta_2^2)$. Известно, что $M(\xi) = \theta_1$, и $D(\xi) = \theta_2^2 = M(\xi^2) - (M(\xi))^2$. При этом $M(\xi^2) = \alpha_2$, $(M(\xi))^2 = (\alpha_1)^2$.

Тогда легко получить следующие оценки методом моментов $\hat{\theta}_1 = \hat{\alpha}_1$, $\hat{\theta}_2 = \sqrt{\hat{\alpha}_2 - (\hat{\alpha}_1)^2}$. При этом, данные оценки будут состоятельными.

3.2 Метод максимального правдоподобия

Рассмотрим еще один метод построения оценок неизвестных параметров. Оценки полученные методом, рассмотренным в этом разделе принято называть *оценками максимального правдоподобия*.

Пусть есть выборка $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$. Пусть $f_\theta(x)$ — функция плотности случайной величины ξ , которая известна с точностью до параметра из распределения; (в дискретном случае вместо функции плотности берем функцию вероятности $P_\theta(\xi = x)$). Пусть \bar{x} — реализация выборки, $\bar{x} = (x_1, \dots, x_n)$.

Определение 3.2. Функцию, заданную равенством $L(\bar{x}; \theta) = \prod_{i=1}^n f_\theta(x_i)$ будем называть функцией правдоподобия.

Фактически функция правдоподобия совпадает с плотностью \bar{x} как вектора.

Если для двух значений параметра $\theta_1, \theta_2 \in \Theta$ $L(\bar{x}; \theta_1) > L(\bar{x}; \theta_2)$, то говорят, что θ_1 более правдоподобна, чем θ_2 .

Определение 3.3. Оценкой максимального правдоподобия называется построенная по реализации выборки \bar{x} значение $\hat{\theta} = \arg \max_{\theta \in \Theta} L(\bar{x}; \theta)$.

То есть, чтобы найти оценку максимального правдоподобия (о.м.п.), надо найти такое значение θ , при котором функция правдоподобия принимает максимальное значение.

Если для каждого \bar{x} из выборочного пространства максимум $L(\bar{x}; \theta)$ достигается в некоторой внутренней точке и $L(\bar{x}; \theta)$ дифференцируема по θ , то $\hat{\theta}(\bar{x})$ удовлетворяет условию

$$\frac{\partial L(\bar{x}; \theta)}{\partial \theta} = 0.$$

В случае векторного параметра $\theta = (\theta_1, \theta_2, \dots, \theta_r)$ условие на максимум функции правдоподобия представляется системой

$$\left\{ \frac{\partial L(\bar{x}; \theta)}{\partial \theta_i} = 0, i = \overline{1, r}. \right.$$

Вместо функции правдоподобия для простоты часто рассматривают следующую функцию $\ln L(\bar{x}; \theta) = \sum_{i=1}^n \ln f_{\theta}(x_i)$.

Пример 3.4. Рассмотрим выборку из распределения $\mathcal{L}(\xi) \sim N(\theta_1, \theta_2^2)$, \bar{x} — реализация выборки.

$$f_{\theta}(x_i) = \frac{1}{\theta_2 \cdot \sqrt{2\pi}} \cdot \exp\left(\frac{-\frac{1}{2} \cdot (x_i - \theta_1)^2}{\theta_2^2}\right).$$

Выпишем функцию правдоподобия:

$$L(\bar{x}; \theta) = \frac{1}{\theta_2^n \cdot (2\pi)^{n/2}} \cdot \prod_{i=1}^n \exp\left(\frac{-\frac{1}{2} \cdot (x_i - \theta_1)^2}{\theta_2^2}\right)$$

и прологарифмируем ее:

$$\ln L(\bar{x}; \theta) = -n \cdot \ln \theta_2 - \frac{n}{2} \cdot \ln[2\pi] - \frac{1}{2} \cdot \sum_{i=1}^n \frac{(x_i - \theta_1)^2}{\theta_2^2}.$$

Продифференцировав по θ_1 и θ_2 получаем систему уравнений:

$$\begin{cases} \frac{\partial(\ln[L(\bar{x}; \theta)])}{\partial \theta_1} = \frac{1}{\theta_2^2} \cdot \sum_{i=1}^n (x_i - \theta_1) = 0 \\ \frac{\partial(\ln[L(\bar{x}; \theta)])}{\partial \theta_2} = -\frac{n}{\theta_2} + \frac{1}{\theta_2^3} \cdot \sum_{i=1}^n (x_i - \theta_1)^2 = 0 \end{cases}$$

$$\begin{cases} \hat{\theta}_1 = \frac{1}{n} \cdot \sum_{i=1}^n x_i = \hat{\alpha}_1, \\ \hat{\theta}_2^2 = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \theta_1)^2; \end{cases}$$

$$\begin{cases} \hat{\theta}_1 = \hat{\alpha}_1, \\ \hat{\theta}_2 = \sqrt{\hat{\alpha}_2 - 2\hat{\alpha}_1^2 + \hat{\alpha}_1^2} = \sqrt{\hat{\alpha}_2 - \hat{\alpha}_1^2}; \end{cases}$$

Заметим, что система имеет одно решение, поскольку точка экстремума единственная и при $\theta_1, \theta_2 \rightarrow \infty$ получаем, что $L(\bar{x}; \theta) \rightarrow 0$, то есть на концах отрезка функция правдоподобия убывает.

Оценка, полученная методом моментов, совпала с оценкой максимального правдоподобия, однако это не всегда так.

Важным свойством оценок максимального правдоподобия является их инвариантность относительно преобразований параметра. Это означает, что если $q = q(\theta)$ — произвольная функция, взаимно однозначно отображающая параметрическое множество Θ рассматриваемой модели в некоторое множество Q , то о.м.п. в Q будет $\hat{q} = q(\hat{\theta})$, где $\hat{\theta}$ — о.м.п. в параметрическом семействе Θ . Принцип инвариантности позволяет в каждой конкретной задаче выбирать наиболее удобную параметризацию, а о.м.п. получать затем с помощью соответствующих преобразований.

4 Сравнения различных оценок

В предыдущем разделе были рассмотрены различные подходы к построению статистических оценок. В данном разделе ответим на вопрос как сравнивать различные оценки.

4.1 Среднеквадратичный подход к сравнению оценок

Пусть заданно параметрическое семейство распределений: $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$, $X = (X_1, X_2, \dots, X_n)$ — выборка. Пусть получены две оценки T_1, T_2 неизвестного параметра $\tau = \tau(\theta)$.

Определение 4.1. Будем говорить что оценка T_1 , лучше оценки T_2 в среднеквадратическом смысле, если

$$M_\theta (T_1 - \tau)^2 < M_\theta (T_2 - \tau)^2.$$

Определение 4.2. Функцию $r = \sqrt{M_\theta(T - \tau)^2}$ называют среднеквадратическим отклонением оценки T .

Определение 4.3. Среднеквадратической ошибкой оценки T параметра $\tau(\theta)$ будем называть величину $\Delta T = M_\theta(T - \tau)^2$

Заметим, что ΔT порождает критерий оптимальности оценок. Класс несмещенных оценок параметра τ будем обозначать \mathcal{T}_τ .

Определение 4.4. Оценку минимизирующую среднеквадратическое отклонение в классе несмещенных оценок будем называть оптимальной оценкой $T^* = \arg \min_{T \in \mathcal{T}_\tau} \Delta T$.

Утверждение 4.5. Для несмещенной оценок среднеквадратическая ошибка совпадает с ее дисперсией, а для смещенной оценки больше ее дисперсии.

Доказательство.

$$\begin{aligned} \mathbf{M}_\theta(T - \tau)^2 &= \mathbf{M}_\theta(T - \mathbf{M}_\theta T + \mathbf{M}_\theta T - \tau)^2 = \\ &= \underbrace{\mathbf{M}_\theta(T - \mathbf{M}_\theta T)^2}_{D_\theta T} + \underbrace{\mathbf{M}_\theta(\mathbf{M}_\theta T - \tau)^2}_b + \underbrace{2 \mathbf{M}_\theta(T - \mathbf{M}_\theta T)(\mathbf{M}_\theta T - \tau)}_0 = \\ &= D_\theta T + b^2. \end{aligned}$$

□

Теорема 4.6. Пусть T_1 и T_2 две оптимальные оценки для неизвестного параметра $\tau = \tau(\theta)$. Тогда $T_1 = T_2$.

Доказательство. Пусть $D = D_\theta T_1 = D_\theta T_2$. Обозначим $\Delta_k = T_k - \tau$, $k \in \overline{1,2}$. Рассмотрим оценку

$$\hat{T} = \frac{T_1 + T_2}{2}.$$

Очевидно, что \hat{T} также будет несмещенной оценкой.

$$\left(\frac{\Delta_1 + \Delta_2}{2}\right)^2 + \left(\frac{\Delta_1 - \Delta_2}{2}\right)^2 = \frac{\Delta_1^2}{2} + \frac{\Delta_2^2}{2}.$$

Рассмотрим подробнее выражения в скобках:

$$\begin{aligned} \frac{\Delta_1 + \Delta_2}{2} &= \frac{T_1 - \tau + T_2 - \tau}{2} = \hat{T} - \tau; \\ \frac{\Delta_1 - \Delta_2}{2} &= \frac{T_1 - \tau - T_2 + \tau}{2} = \frac{T_1 - T_2}{2}. \end{aligned}$$

После подстановки и вычисления математического ожидания от левой и правой части получаем:

$$\mathbf{M}_\theta \left(\hat{T} - \tau \right)^2 + \frac{1}{4} \mathbf{M}_\theta (T_1 - T_2)^2 = D.$$

Так как $\mathbf{M}_\theta \left(\hat{T} - \tau \right)^2 \geq D$, то получаем, что $D(T_1 - T_2) = 0$, что доказывает теорему. □

Пример 4.7. Рассмотрим выборку $X = (X_1, \dots, X_n)$ из $\mathcal{L}(\xi)$, $\xi \sim Bi(1, \theta)$, $\theta \in (0, 1)$. Хотим оценить параметр θ . Напомним, что $\mathbb{M} X_i = \theta$, $\mathbb{D} X_i = \theta(1 - \theta)$.

Множество несмещенных оценок не пусто. Действительно, статистика $\frac{1}{n} \sum_{i=1}^n x_i = \hat{\alpha}$ как известно является несмещенной оценкой параметра θ :

$$\mathbb{M} \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n \mathbb{M} X_i = \frac{n}{n} \theta = \theta.$$

Эта оценка является состоятельной:

$$\mathbb{D} \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n^2} \sum_{i=1}^n \mathbb{D} X_i = \frac{n\theta(1 - \theta)}{n^2} = \frac{\theta(1 - \theta)}{n} \rightarrow 0, n \rightarrow \infty.$$

Заметим, что таких оценок бесконечно много. Пусть $b_1 + \dots + b_n = n$. Рассмотрим статистику T вида

$$T(X) = \frac{1}{n} \sum_{i=1}^n b_i X_i,$$

которая является как несмещенной так и состоятельной:

$$\mathbb{D} T(X) = \frac{1}{n^2} \sum_{i=1}^n b_i^2 \theta(1 - \theta) \leq \frac{b^2}{n^2} n \theta(1 - \theta) \leq \frac{b^2}{n} \rightarrow 0, n \rightarrow \infty,$$

где $b = \max(b_1, \dots, b_n)$.

Покажем, что для любой оценки

$$\mathbb{D}_\theta \geq \frac{\theta(1 - \theta)}{n} \quad \forall \theta \in (0, 1),$$

то есть $\hat{\alpha}_1$ является оптимальной и несмещенной оценкой.

Для начала выпишем функцию правдоподобия:

$$L(\bar{x}; \theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i},$$

где \bar{x} — реализация выборки. Очевидно, что

$$\sum_{\bar{x}} L(\bar{x}; \theta) = 1.$$

Пусть T — произвольная несмещенная оценка

$$\theta = \mathbf{M}_\theta T(X) = \sum_{\bar{x}} T(\bar{x}) L(\bar{x}; \theta).$$

Продифференцируем первое равенство по θ :

$$0 = \sum_{\bar{x}} \frac{\partial L(\bar{x}; \theta)}{\partial \theta} = \sum_{\bar{x}} \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} L(\bar{x}; \theta) = \mathbf{M}_\theta \left(\sum_{\bar{x}} \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right), \quad (1)$$

пользуясь следующими равенствами:

$$\frac{\partial \ln f(x)}{\partial x} = \frac{1}{f(x)} \frac{\partial f(x)}{\partial x};$$

$$\frac{\partial f(x)}{\partial x} = \frac{\partial \ln f(x)}{\partial x} f(x).$$

Аналогично продифференцируем второе равенство:

$$1 = \sum_{\bar{x}} T(\bar{x}) \frac{\partial L(\bar{x}; \theta)}{\partial \theta} = \mathbf{M}_\theta \left(T(\bar{x}) \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right). \quad (2)$$

Так как $\mathbf{M}(a \cdot b) \leq \sqrt{\mathbf{M} a^2 \cdot \mathbf{M} b^2}$, то вычтя из (2) умноженное на θ значение (1) получим:

$$1 = \mathbf{M}_\theta \left((T(X) - \theta) \frac{\partial \ln(L(X; \theta))}{\partial \theta} \right) \leq \sqrt{\mathbf{M}_\theta (T(X) - \theta)^2 \mathbf{M}_\theta \left(\frac{\partial \ln(L(X; \theta))}{\partial \theta} \right)^2}.$$

И после возведения левой и правой части в квадрат:

$$1 \leq \mathbf{M}_\theta (T(X) - \theta)^2 \cdot \mathbf{M}_\theta \left(\frac{\partial \ln(L(X; \theta))}{\partial \theta} \right)^2$$

Так как $\mathbf{M}_\theta (T(X) - \theta)^2 = \mathbf{D}_\theta T(X)$, то

$$\mathbf{D}_\theta T(X) \geq \frac{1}{\mathbf{M}_\theta \left(\frac{\partial \ln(L(X; \theta))}{\partial \theta} \right)^2} \quad \forall \theta \in (0; 1).$$

Осталось найти значение математического ожидания в знаменателе. Рассмотрим величину:

$$\begin{aligned}\frac{\partial \ln(L(\bar{x}; \theta))}{\partial \theta} &= \frac{\partial}{\partial \theta} \left(\sum_{i=1}^n x_i \ln \theta + (n - \sum_{i=1}^n x_i) \ln(1 - \theta) \right) = \\ &= \frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1 - \theta} = \frac{(1 - \theta) \sum_{i=1}^n x_i - \theta \sum_{i=1}^n x_i}{\theta(1 - \theta)} = \frac{1}{\theta(1 - \theta)} \sum_{i=1}^n (x_i - \theta).\end{aligned}$$

$$M_\theta \left(\frac{\partial \ln(L(X; \theta))}{\partial \theta} \right)^2 = \frac{1}{\theta^2(1 - \theta)^2} \cdot M_\theta \left(\sum_{i=1}^n (X_i - \theta) \right)^2 = \frac{n \cdot D_\theta X_i}{\theta^2(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}.$$

Теорема 4.8. *Относительная частота произвольного события является оптимальной несмещенной оценкой для вероятности этого события.*

Следствие 4.9. *Значение эмперической функции $\hat{F}_n(x)$ в каждой точке x является оптимальной несмещенной оценкой для значения $F(x)$.*

4.2 Эффективные оценки. Неравенство Рао-Крамера.

Пусть заданно параметрическое семейство распределений: $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$, $X = (X_1, X_2, \dots, X_n)$ — выборка, $\bar{x} = (x_1, \dots, x_n)$ — реализация выборки.

Определение 4.10. *Параметрическое семейство $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ называется регулярным (по Рао-Крамеру), если выполнены следующие условия, которые в дальнейшем будем называть условиями регулярности:*

1. $L(\bar{x}; \theta) > 0$ для всех значений $\bar{x} \in B$ из выборочного пространства и дифференцируема по θ , $\forall \theta \in \Theta$ (Θ — параметрическое множество).
2. Случайная величина $V(X; \theta)$, называемая функцией вклада выборки и определенная равенством

$$V(X; \theta) = \frac{\partial \ln(L(X; \theta))}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln(f_\theta(X_i))}{\partial \theta},$$

имеет ограниченную дисперсию:

$$0 < M_\theta V^2(X; \theta) < \infty.$$

При этом значение $\frac{\partial \ln(f_\theta(X_i))}{\partial \theta}$ будем называть вкладом i -го наблюдения выборки.

3. $\forall \theta \in \Theta \forall$ статистики $T(X)$ верно равенство:

$$\frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} T(\bar{x}) L(\bar{x}; \theta) d\bar{x} = \int_{\mathbb{R}^n} T(\bar{x}) \frac{\partial L(\bar{x}; \theta)}{\partial \theta} d\bar{x}.$$

Рассмотрим некоторые свойства вклада выборки $V(\bar{x}; \theta)$. Воспользуемся известным равенством:

$$\int_{\mathbb{R}^n} L(\bar{x}; \theta) d\bar{x} = 1.$$

Откуда продифференцировав по θ получаем:

$$\begin{aligned} 0 &= \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} L(\bar{x}; \theta) d\bar{x} = \int_{\mathbb{R}^n} \frac{\partial L(\bar{x}; \theta)}{\partial \theta} d\bar{x} = \int_{\mathbb{R}^n} \frac{\partial \ln(L(\bar{x}; \theta))}{\partial \theta} L(\bar{x}; \theta) d\bar{x} = \\ &= \mathbf{M}_\theta \frac{\partial \ln(L(X); \theta)}{\partial \theta} = \mathbf{M}_\theta V(X; \theta). \end{aligned}$$

Для регулярных моделей определена $\mathbf{D}_\theta V(X)$ корректно и равна $\mathbf{M}_\theta V^2(X)$.

Определение 4.11. Функцию $i_n(\theta)$, определенную равенством:

$$i_n(\theta) = \mathbf{D}_\theta V(X; \theta) = \mathbf{M}_\theta V^2(X; \theta)$$

будем называть информацией Фишера.

Заметим, что верно равенство:

$$i_n(\theta) = \mathbf{D}_\theta V(X; \theta) = \sum_{i=1}^n \mathbf{D} f(x_i; \theta) = n \cdot i_1(\theta) = n \cdot i(\theta)$$

Теорема 4.12. Неравенство Рао-Крамера.

Пусть $\tau(\theta)$ — неизвестный параметр в регулярной модели $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ и θ — скалярный параметр. Пусть также $\tau(\theta)$ — дифференцируема по θ .

Тогда для любой оценки $T = T(X)$ параметр $\tau(\theta)$, $T \in \mathcal{T}_\tau$ справедливо неравенство:

$$\mathbf{D}_\theta T(X) \geq \frac{[\tau'(\theta)]^2}{n \cdot i(\theta)}.$$

При этом равенство выполняется тогда и только тогда, когда:

$$T(X) - \tau(\theta) = a(\theta) \cdot V(X; \theta),$$

где $a(\theta)$ — некоторая функция.

Доказательство.

$$\mathbf{M}_\theta T(X) = \int_{\mathbb{R}^n} T(\bar{x}) L(\bar{x}; \theta) d\bar{x} = \tau(\theta)$$

так как оценка несмещенная. В виду регулярности модели:

$$\begin{aligned} \tau'(\theta) &= \int_{\mathbb{R}^n} T(\bar{x}) \frac{\partial \ln(L(\bar{x}; \theta))}{\partial \theta} L(\bar{x}; \theta) d\bar{x} = \mathbf{M}_\theta \left(T(\bar{x}) \cdot \frac{\partial \ln(L(\bar{x}; \theta))}{\partial \theta} \right) = \\ &= \mathbf{M}_\theta(T(X) V(X; \theta)). \end{aligned}$$

$$\begin{aligned} \tau'(\theta) &= \mathbf{M}_\theta(T(X) V(X; \theta)) = \mathbf{M}_\theta((T(X) + \tau(\theta) - \tau(\theta)) \cdot V(X; \theta)) = \\ &= \mathbf{M}_\theta((T(X) - \tau(\theta)) V(X; \theta)) + \tau(\theta) \mathbf{M}_\theta V(X; \theta) = \\ &= \mathbf{M}_\theta(T(X) - \tau(\theta)) \cdot (V(X; \theta) - \mathbf{M}_\theta V(X; \theta)) = \text{cov}_\theta(T(X); V(X; \theta)). \end{aligned}$$

Используя неравенство Коши-Буняковского $\text{cov}(\xi, \eta)^2 \leq \mathbf{D} \xi \mathbf{D} \eta$:

$$\tau'(\theta)^2 \leq \mathbf{D}_\theta T(X) \cdot \mathbf{D}_\theta V(X, \theta) = \mathbf{D}_\theta T(X) \cdot i_n(\theta)$$

Напомним, что неравенство Коши-Буняковского превращается в равенство, если ξ, η линейно связаны: $\xi = a\eta + b$. В нашем случае:

$$T(X) = aV(X; \theta) + b.$$

Вычислим математическое ожидание от левой и правой части:

$$b = \mathbf{M}_\theta T(X) - a \mathbf{M}_\theta V(X; \theta)$$

Так как $\mathbf{M}_\theta T(X) = \tau(\theta)$ и $\mathbf{M}_\theta V(X; \theta) = 0$, то:

$$T(X) = aV(X; \theta) + \tau(\theta).$$

Следовательно для любого значения θ существует такое $a = a(\theta)$, что завершает доказательство теоремы. \square

Следствие 4.13. Если $D_\theta T(X) = \frac{[\tau'(\theta)]^2}{n \cdot i(\theta)}$, то в этом случае $D_\theta T(X) = a(\theta) \cdot \tau'(\theta)$

Доказательство.

$$\text{cov}_\theta(T(X); V(X; \theta)) = \tau'(\theta)$$

$$\text{cov}_\theta(T(X); V(X; \theta)) = M_\theta(T(X) \cdot V(X; \theta)) - M_\theta T(X) \cdot M_\theta V(X; \theta)$$

Так как $M_\theta T(X) \cdot M_\theta V(X; \theta) = 0$, то

$$M_\theta(T(X) \cdot V(X; \theta)) = M_\theta \left(T(X) \cdot \frac{T(X) - \tau(\theta)}{a(\theta)} \right) = \frac{1}{a(\theta)} M_\theta(T^2(X) - T(X)),$$

откуда получаем:

$$\tau'(\theta) = \frac{1}{a(\theta)} D_\theta T(X).$$

\square

Замечание 4.14. Если $T(X)$ - смещенная оценка, $M_\theta T(X) = \tau(\theta) + b(\theta)$, то

$$D_\theta T(X) \leq \frac{[\tau'(\theta) + b'(\theta)]^2}{n \cdot i(\theta)}.$$

Следствие 4.15. Если $T(X)$ является несмещенной оценкой для θ , то:

$$D_\theta T(X) \leq \frac{1}{n \cdot i(\theta)}.$$

Определение 4.16. Эффективностью оценки $T = T(X)$ параметра $\tau(\theta)$ будем называть величину

$$e(T) = \frac{(\tau'(\theta))^2}{i_n(\theta) D_\theta T}, \quad 0 \leq e(T) \leq 1.$$

Если выполняется равенство $e(t) = 1$, то в этом случае оценка $T(X)$ называется эффективной.

Заметим, что ранее, в частности было показано, что

$$\frac{\theta(1-\theta)}{n} V(X; \theta) = \bar{X} - \theta.$$

Тогда положив $\tau(\theta) = \theta$ и $a(\theta) = \theta(1 - \theta)/n$ получим, что статистика \bar{X} является эффективной оценкой параметра в модели $Bi(1, \theta)$. Рассмотрим еще примеры эффективных статистик.

Пример 4.17. Рассмотрим выборку $X = (X_1, \dots, X_n)$ из $\mathcal{L}(\xi)$, $\xi \sim N(\theta, \sigma^2)$. Выпишем вклад одного наблюдения:

$$V(X_1, \theta) = \frac{\partial \ln f_\theta(X_1)}{\partial \theta} = \frac{\partial}{\partial \theta} \ln \left(\left(\frac{1}{\sqrt{2\pi}\sigma} \right) \exp \left(-\frac{(X_1 - \theta)^2}{2\sigma^2} \right) \right) = \frac{X_1 - \theta}{\sigma^2}.$$

Заметим, что $f_\theta(X_1)$ — дважды дифференцируема и $M_\theta(V(X, \theta)) = 0$, откуда:

$$\begin{aligned} \frac{\partial}{\partial \theta} M_\theta(V(X, \theta)) &= \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} \frac{\partial \ln f_\theta(\bar{x})}{\partial \theta} f_\theta(\bar{x}) d\bar{x} = \\ &= \int_{\mathbb{R}^n} \frac{\partial^2 \ln f_\theta(\bar{x})}{\partial^2 \theta} f_\theta(\bar{x}) d\bar{x} + \int_{\mathbb{R}^n} \left(\frac{\partial \ln f_\theta(\bar{x})}{\partial \theta} \right)^2 f_\theta(\bar{x}) d\bar{x}, \end{aligned}$$

откуда получаем, что $M_\theta \frac{\partial^2 \ln f_\theta(X_1)}{\partial^2 \theta} = -i_1(\theta)$ — информация Фишера. Таким образом доказано следующее

Утверждение 4.18. Если плотность случайной величины ξ дважды дифференцируема, то

$$-M_\theta \frac{\partial^2 \ln f_\theta(X_1)}{\partial^2 \theta} = i_1(\theta).$$

Вернемся к примеру и воспользуемся доказанным утверждением:

$$\frac{\partial^2 \ln f_\theta(X_1)}{\partial \theta^2} = -\frac{1}{\sigma^2}.$$

Откуда получаем, что $i(\theta) = \frac{1}{\sigma^2}$.

Рассмотрим статистику

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

и покажем, что она эффективная оценка параметра θ . Действительно,

$$\frac{1}{ni(\theta)} = \frac{\sigma^2}{n} = D_\theta \bar{X}.$$

Также можно заметить, что

$$\frac{\sigma^2}{n}V(X; \theta) = \overline{X} - \theta.$$

4.3 О доказательстве регулярности модели

Для доказательства регулярности модели необходимо показать возможность перестановки знаков дифференцирования и интегрирования. Напомним следующую теорему из курса математической статистики, которая в большинстве случаев помогает доказать свойство регулярности:

Теорема 4.19. Пусть функция $f(x, \theta)$, определенная в прямоугольнике $[a, b; c, d]$, будет непрерывна по x в $[a, b]$ при любом постоянном θ в $[c, d]$. Предположим, что во всей области существует частная производная $\frac{\partial f(x, \theta)}{\partial \theta}$, непрерывная как функция двух переменных. Тогда при любом θ из $[c, d]$ имеет место формула

$$\frac{\partial}{\partial \theta} \int_a^b f(x, \theta) dx = \int_a^b \frac{\partial f(x, \theta)}{\partial \theta} dx.$$

Аналогично для несобственного интеграла:

Теорема 4.20. Если:

- функции $f(x, \theta)$, $\frac{\partial f(x, \theta)}{\partial \theta}$ непрерывны на множестве $\{(x, \theta) \in \mathbb{R}^2 \mid x \in [a, \omega), \theta \in [c, d]\}$,
- интеграл

$$\Phi(\theta) = \int_a^\omega \frac{\partial f(x, \theta)}{\partial \theta} dx$$

сходится равномерно на множестве $Y = [c, d]$,

- интеграл

$$F(\theta) = \int_a^\omega f(x, \theta) dx$$

сходится хотя бы при одном значении $\theta_0 \in Y$,

то он сходится и даже равномерно на всем множестве Y , при этом функция $F(\theta)$ оказывается дифференцируемой и справедливо равенство

$$\frac{\partial F(\theta)}{\partial \theta} = \int_a^\omega \frac{\partial f(x, \theta)}{\partial \theta} dx.$$

В эквивалентной форме условия регулярности можно переписать следующим образом:

- Существует такое множество C , что $P_\theta(\xi) = 1$, что при каждом $y \in C$ функция $\sqrt{f_\theta(y)}$ непрерывно дифференцируема по θ всюду в области Θ ,
- информация Фишера $i_n(\theta)$ существует, положительна и непрерывна по θ во всех точках $\theta \in \Theta$.

4.4 Экспоненциальное семейство

Определение 4.21. *Параметрическое семейство $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ называется экспоненциальным, если плотность $f_\theta(x)$ имеет следующий вид:*

$$f_\theta(x) = \exp \{A(\theta) \cdot B(x) + C(\theta) + D(x)\}.$$

Заметим, что следующие модели очевидно являются экспоненциальными: $N(\theta, \sigma^2)$, $N(\mu, \theta^2)$, $\Gamma(\theta, \lambda)$, $Bi(k, \theta)$, $\overline{Bi}(r, \theta)$, $Pois(\theta)$, $R(0, \theta)$.

Надем вклад выборки для экспоненциальной модели:

$$\begin{aligned} V(X; \theta) &= \frac{\partial \ln \prod_{i=1}^n f_\theta(X_i)}{\partial \theta} = A'(\theta) \sum_{i=1}^n B(X_i) + nC'(\theta) = \\ &= nA'(\theta) \left(\frac{1}{n} \sum_{i=1}^n B(X_i) + \frac{C'(\theta)}{A'(\theta)} \right). \end{aligned}$$

Рассмотрим статистику

$$T(X) = \frac{1}{n} \sum_{i=1}^n B(X_i)$$

и покажем, что $T(X)$ является эффективной оценкой параметра

$$\tau(\theta) = -\frac{C'(\theta)}{A'(\theta)}.$$

Действительно, пользуясь неравенством Рао-Крамера получаем, что

$$T(x) - \tau(\theta) = \underbrace{\frac{1}{nA'(\theta)}}_{a(\theta)} \cdot V(X; \theta).$$

Таким образом в случае регулярности параметрического семейства статистика $T(X)$ является эффективной оценкой для параметрической функции $\tau(\theta)$. Более того, согласно следствию 4.13 к теореме Рао-Крамера получаем:

$$D_\theta T = \frac{\tau'(\theta)}{nA'(\theta)}.$$

Пример 4.22. Заметим, что условие регулярности здесь играет очень важную роль. Действительно, легко показать, что параметрическое семейство $R(0, \theta)$ является экспоненциальным, однако оно не является регулярным. Покажем, что семейство $R(0, \theta)$ не является регулярным. Воспользуемся тождеством

$$\int_0^\theta \frac{dx}{\theta} = 1.$$

Если модель регулярна, то должно выполняться следующее равенство:

$$\int_0^\theta \frac{\partial}{\partial \theta} \frac{dx}{\theta} = 0,$$

что неверно.

На самом деле верно и обратное утверждение: если существует эффективная оценка для некоторой функции $\tau(\theta)$, то семейство является регулярным. Чтобы доказать это воспользуемся равенством из теоремы Рао-Крамера:

$$(T(X) - \tau(\theta)) \cdot a^{-1}(\theta) = V(X; \theta)$$

и проинтегрируем его по θ :

$$A_1(\theta)T(X) + C_1(\theta) + D_1(X) = \ln L(X; \theta).$$

Отсюда однозначно определяется вид плотности распределения.

Для регулярных экспоненциальных семейств функцию информации можно вычислить по следующей формуле:

$$i(\theta) = \frac{(\tau'(\theta))^2}{D_\theta T(X)} = \frac{(\tau'(\theta))^2}{a(\theta) \cdot \tau'(\theta)} = \tau'(\theta) \cdot A'(\theta) = \left(-\frac{C'(\theta)}{A'(\theta)} \right)' \cdot A'(\theta) = \\ = \frac{C'(\theta)A''(\theta)}{A'(\theta)} - C''(\theta).$$

5 Условное математическое ожидание

Рассмотрим вероятностное пространство (Ω, \mathcal{F}, P) и заданную на нем случайную величину ξ . В курсе теории вероятности определялось понятие условной вероятности события $C \in \mathcal{F}$ при условии, что происходит некоторое событие $B \in \mathcal{F}$:

$$P(C|B) = \frac{P(CB)}{P(B)}.$$

Если событие B фиксировано, то совокупность условных вероятностей $P(C|B)$, $C \in \mathcal{F}$, задает на измеримом пространстве (Ω, \mathcal{F}) новую вероятностную меру P_B , $P_B(C) = P(B|C)$, сосредоточенную на множестве B :

$$P_B(B) = 1, P_B(\Omega \setminus B) = 0.$$

Пусть ξ — случайная величина: заданная на (Ω, \mathcal{F}, P) и принимающая значения из конечного или счетного множества $X = \{x_1, x_2, \dots\}$. Этой случайной величине соответствует разбиение $\{A_1, A_2, \dots\}$ пространства Ω на непесекающиеся \mathcal{F} -измеримые множества

$$A_k = \{\omega \in \Omega: \xi(\omega) = x_k\} \in \mathcal{F}, k \geq 1,$$

порождающие σ -алгебру $\sigma(\xi)$. В этом случае математическое ожидание ξ можно вычислить как относительно основного разбиения P :

$$M\xi = \sum_{\omega \in \Omega} \xi(\omega)P(\omega) = \sum_{k \geq 1} x_k P(A_k),$$

так и относительно условного распределения P_B :

$$M(\xi|B) = \sum_{\omega \in \Omega} \xi(\omega)P(\omega|B) = \sum_{k \geq 1} x_k P(A_k|B).$$

Пусть $(\Omega, \mathcal{F}, \mathbf{P})$ — вероятностное пространство и $\mathcal{B} = \{B_1, B_2, \dots\}$ — измеримое разбиение Ω на множества положительной меры. Заметим, что здесь и далее все разбиения будем считать измеримыми, не оговаривая это специально.

Рассмотрим произвольное событие $C \in \mathcal{F}$. Для данного события определены условные вероятности $\mathbf{P}(C|B_k)$, $k \geq 1$. Введем случайную величину, определив измеримую функцию на Ω , которая на множестве B_k принимает значение $\mathbf{P}(C|B_k)$:

$$\xi_{\mathcal{B}} = \xi_{\mathcal{B}}(\omega) = \sum_{k \geq 1} \mathbf{P}(C|B_k) \text{Ind}(\omega \in B_k) = \mathbf{P}(C|\mathcal{B}).$$

Случайная величина $\xi_{\mathcal{B}}(\omega)$ называется *условной вероятностью события C относительно разбиения \mathcal{B}* .

Такое определение позволяет сравнивать условные вероятности относительно разных разбиений, поскольку эти условные вероятности являются функциями с общей областью определения Ω . Например, пусть ξ и η — независимые случайные величины, принимающие значения $\{x_1, \dots, x_n\}$ и $\{y_1, \dots, y_m\}$ и порождающие разбиения $\mathcal{A} = \{A_1, \dots, A_n\}$ и $\mathcal{B} = \{B_1, \dots, B_m\}$,

$$\mathbf{P}(\xi = x_i) = p_i, \quad i \in \overline{1, n},$$

$$\mathbf{P}(\eta = y_j) = q_j, \quad j \in \overline{1, m}.$$

Тогда при любом $i \in \overline{1, n}$

$$\mathbf{P}(A_i|\mathcal{B}) = \mathbf{P}(\xi = x_i|\mathcal{B}) = \mathbf{P}(\xi = x_i) = p_i.$$

В тоже время

$$\mathbf{P}(A_i|\mathcal{A}) = \mathbf{P}(\xi = x_i|\mathcal{A}) = \text{Ind}(x \in A_i),$$

то есть условные вероятности относительно разбиения \mathcal{B} являются константами со значениями p_1, \dots, p_n (что соответствует независимости событий), а относительно разбиения \mathcal{A} — ступенчатыми функциями, принимающими только два значения: 0 и 1.

В терминах условных вероятностей стандартная формула полной вероятности

$$P(C) = \sum_{k \geq 1} P(C | B_k) P(B_k), \quad B_i \cap B_j = \emptyset, \quad i \neq j, \quad \bigcup_{k \geq 1} B_k = \Omega,$$

принимает другой вид. Заменим в ней $P(B_k)$ на $M \text{Ind}(\omega \in B_k)$ и воспользуемся аддитивностью математического ожидания:

$$\begin{aligned} P(C) &= \sum_{k \geq 1} P(C | B_k) P(B_k) = \sum_{k \geq 1} P(C | B_k) M \text{Ind}(\omega \in B_k) = \\ &= M \sum_{k \geq 1} P(C | B_k) \text{Ind}(\omega \in B_k) = M P(C | \mathcal{B}), \end{aligned}$$

где $\mathcal{B} = \{B_1, B_2, \dots\}$ — разбиение, или

$$P(C) = M P(C | \mathcal{B}).$$

Если разбиение \mathcal{B} порождается случайной величиной η , то говорят, об *условной вероятности относительно случайной величины η* или относительно порожденной ею σ -алгебры $\sigma(\eta)$:

$$P(C | \eta) = P(C | \sigma(\eta)) = P(C | \eta)(\omega).$$

Замечание 5.1. Так как случайная величина η на каждом элементе порожденного ей разбиения постоянна, то условная вероятность $P(C | \eta)$ есть *функция от C и $\eta(\omega)$* .

Рассмотрим теперь аналогичную конструкцию для случайных величин. Пусть на вероятностном пространстве (Ω, \mathcal{F}, P) заданы:

- разбиение $\mathcal{B} = \{B_1, B_2, \dots\}$;
- случайная величина ξ с конечным или счетным множеством значений $x_1, x_2, \dots \in \mathbb{R}$;
- порожденное случайной величиной разбиение $\mathcal{A} = \{A_1, A_2, \dots\}$ пространства Ω на непересекающиеся множества

$$A_k = \{\omega \in \Omega: \xi(\omega) = x_k\} \in \mathcal{F}, \quad k \geq 1.$$

$$\mathbf{P}(A_k | \mathcal{B}) = \mathbf{P}(A_k | \mathcal{B})(\omega) = \mathbf{P}(\xi = x_k | \mathcal{B})(\omega), \omega \in \Omega,$$

определены для всех $k \geq 1$, и для каждого $\omega \in \Omega$ они образуют вероятностное распределение на множестве $\{x_1, x_2, \dots\}$ значений ξ , зависящее от ω . Определим *условное математическое ожидание ξ относительно разбиения \mathcal{B}* как функцию, отображающую Ω в \mathbb{R} (т.е. как случайную величину):

$$\mathbf{M}(\xi | \mathcal{B})(\omega) = \sum_{k \geq 1} x_k \mathbf{P}(A_k | \mathcal{B})(\omega) = \sum_{k \geq 1} x_k \mathbf{P}(\xi = x_k | \mathcal{B})(\omega).$$

Преобразуем последнюю формулу:

$$\begin{aligned} \mathbf{M}(\xi | \mathcal{B})(\omega) &= \sum_{k \geq 1} x_k \mathbf{P}(A_k | \mathcal{B})(\omega) = \sum_{k \geq 1} x_k \sum_{j \geq 1} \mathbf{P}(A_k | B_j) \text{Ind}(\omega \in B_j) = \\ &= \sum_{j \geq 1} \text{Ind}(\omega \in B_j) \sum_{k \geq 1} x_k \mathbf{P}(A_k | B_j) = \sum_{j \geq 1} \text{Ind}(\omega \in B_j) \mathbf{M}(\xi | B_j). \end{aligned}$$

Таким образом, условное математическое ожидание ξ относительно разбиения \mathcal{B} есть случайная величина, принимающая на каждом элементе B_j этого разбиения постоянное значения равное $\mathbf{M}(\xi | B_j)(\omega)$. Отсюда следует, что $\mathbf{M}(\xi | \mathcal{B})(\omega)$ — функция измеримая относительно разбиения \mathcal{B} . Действительно, для любого \mathcal{B} -измеримого множества D событие $\{\omega: \mathbf{M}(\xi | \mathcal{B}) \in D\}$ является объединением множеств B_j , то есть принадлежит σ -алгебре, порожденной разбиением \mathcal{B} .

Пример 5.2. Пусть $\Omega = [0, 1)$, $\xi(\omega) = \omega$ и σ -алгебра \mathcal{B} порождается множествами $[0, \frac{1}{5})$, $[\frac{1}{5}, \frac{2}{5})$, $[\frac{2}{5}, \frac{3}{5})$, $[\frac{3}{5}, \frac{4}{5})$, $[\frac{4}{5}, 1)$. Тогда случайную величину $\mathbf{M}(\xi | \mathcal{B})$ можно описать таблицей

B_j	$[0, \frac{1}{5})$	$[\frac{1}{5}, \frac{2}{5})$	$[\frac{2}{5}, \frac{3}{5})$	$[\frac{3}{5}, \frac{4}{5})$	$[\frac{4}{5}, 1)$
$\mathbf{M}(\xi \mathcal{B})(\omega)$	$\frac{1}{10}$	$\frac{3}{10}$	$\frac{1}{2}$	$\frac{7}{10}$	$\frac{9}{10}$

Утверждение 5.3. Для любой случайной величины ξ и для любого события C , измеримого относительно разбиения $\mathcal{B} = \{B_1, B_2, \dots\}$, справедлива формула

$$\mathbf{M} \text{Ind}(\omega \in C) \cdot \xi(\omega) = \mathbf{M}(\text{Ind}(\omega \in C) \cdot \mathbf{M}(\xi | \mathcal{B})).$$

Доказательство. Действительно, так как C измеримо относительно \mathcal{B} , то

$$C = \bigcup_{j: B_j \in C} B_j$$

и

$$\begin{aligned} \mathbb{M} \text{Ind}(\omega \in C) \cdot \xi(\omega) &= \sum_{j: B_j \in C} \sum_{\omega \in B_j} \xi(\omega) \mathbb{P}(\omega) = \\ &= \sum_{j: B_j \in C} \sum_{\omega \in B_j} \xi(\omega) \mathbb{P}(\omega | B_j) \mathbb{P}(B_j) = \sum_{j: B_j \in C} \mathbb{M}(\xi | B_j) \mathbb{P}(B_j) = \\ &= \sum_{j: B_j \in C} \mathbb{M}(\xi | B_j) \sum_{\omega \in B_j} \mathbb{P}(\omega) = \sum_{\omega \in C} \mathbb{M}(\xi | \mathcal{B})(\omega) \mathbb{P}(\omega) = \mathbb{M}(\text{Ind}(\omega \in C) \cdot \mathbb{M}(\xi | \mathcal{B})). \end{aligned}$$

□

Следствие 5.4. Для любой случайной величины ξ и любого разбиения \mathcal{B} справедлива формула полного математического ожидания:

$$\mathbb{M} \xi = \mathbb{M} \mathbb{M}(\xi | \mathcal{B}).$$

Аналогично (хоть и использованием много более сложного математического аппарата) определяется условное математическое ожидание, когда разбиение \mathcal{B} порождаются величинами, имеющими непрерывные распределения. В этом случае условное математическое ожидание случайной величины ξ относительно σ -алгебры \mathcal{B} называется случайная величина $\mathbb{M}(\xi | \mathcal{B})$, измеримая относительно \mathcal{B} и удовлетворяющая тождеству:

$$\int_C \xi d\mathbb{P} = \int_C \mathbb{M}(\xi | \mathcal{B}) d\mathbb{P}$$

для любого события $C \in \mathcal{B}$.

Это равенство аналогично определению плотности абсолютно непрерывного распределения — определяется с точностью до множеств, имеющих меру 0.

Для условных математических ожиданий можно доказать следующие свойства:

1. Линейность: для любых случайных величин ξ, η с конечными математическими ожиданиями и чисел a, b справедливо равенство:

$$M(a\xi + b\eta|\mathcal{B}) = a M(\xi|\mathcal{B}) + b M(\eta|\mathcal{B}).$$

2. Если существует $M\xi$, то $M(\xi|\{\emptyset, \Omega\}) = M\xi$.
3. Если распределение случайной величины ξ вырождено, т.е. $P(\xi = C = \text{const}) = 1$, то $M(\xi|\mathcal{B}) = C$.
4. $M(\text{Ind}(A)|\mathcal{B}) = P(A|\mathcal{B})$ для любого $A \in \mathcal{F}$. Действительно, если \mathcal{B} порождается разбиением $\{B_1, B_2, \dots\}$, то в силу свойства (1):

$$\begin{aligned} M(\text{Ind}(A)|\mathcal{B}) &= M\left(\sum_{i \geq 1} \text{Ind}(AB_i) \middle| \mathcal{B}\right) = \\ &= \sum_{i \geq 1} M(\text{Ind}(AB_i)|B_i) \text{Ind}(B_i) = \sum_{i \geq 1} P(A|B_i) \text{Ind}(B_i) = P(A|\mathcal{B}). \end{aligned}$$

5. Если $P(\xi \leq \eta) = 1$, то $M(\xi|\mathcal{B}) \leq M(\eta|\mathcal{B})$. Действительно, для любого $A \in \mathcal{B}$:

$$\begin{aligned} \int_A M(\xi|\mathcal{B}) dP &= M M(\xi|\mathcal{B}) \text{Ind}(A) = M \xi \text{Ind}(A) \leq \\ &\leq M \eta \text{Ind}(A) = \int_A M(\eta|\mathcal{B}) dP, \end{aligned}$$

поэтому $P(M(\eta|\mathcal{B}) - M(\xi|\mathcal{B}) \geq 0) = 1$.

6. Для условных математических ожиданий верны теоремы сходимости, справедливые для обычных математических ожиданий, в частности, теорема о монотонной сходимости и теорема о мажорируемой сходимости.

6 Способы построения оценок

6.1 Достаточные статистики

Определение 6.1. Статистика $T = T(X)$ называется достаточной для параметра $\tau(\theta)$ (в модели $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$), если для любого события $A \subset \mathcal{B}$ условная вероятность $P_\theta(X \in A | T(X) = t)$ не зависит от θ .

Это свойство означает, что статистика T содержит всю информацию о параметре θ , содержащуюся в выборке. Иными словами: статистика T достаточна, если условная плотность $L(\bar{x}|t; \theta)$ выборки $X = (X_1, \dots, X_n)$ при условии $T(X) = t$ не зависит от параметра θ . Очевидно, что сама выборка X , очевидно, является достаточной статистикой так как $P_\theta(X \in A | X = \bar{x})$ при любом θ есть либо 1, если $\bar{x} \in A$, либо 0 в противном случае.

Обычно стараются найти достаточную статистику наименьшей размерности, представляющую данные в наиболее сжатом виде. При наличии достаточной статистики все статистические выводы об исследуемой модели в конечном итоге формулируются в терминах этой статистики.

Пример 6.2. Рассмотрим выборку $X = (X_1, X_2, \dots, X_n)$ из распределения $\mathcal{L}(\xi), \xi \sim \text{Pois}(\lambda)$.

Покажем, что $T(X) = \sum_{i=1}^n X_i$ является достаточной статистикой. Выпишем условную вероятность вектора:

$$P(X = \bar{x} | T(X) = t) = \begin{cases} P(X = \bar{x}), & \sum_{i=1}^n x_i = t \\ 0, & \text{в противном случае.} \end{cases}$$

где $\bar{x} = (x_1, x_2, \dots, x_n)$.

$$\begin{aligned} P(X = \bar{x} | T(X) = t) &= \\ &= \frac{P(X = \bar{x}, T(X) = t)}{P(T(X) = t)} = \frac{P(X = \bar{x})}{\sum_{\bar{x}: T(\bar{x})=t} P(\bar{x})} = \frac{P(X = \bar{x})}{P\left(\sum_{i=1}^n x_i = t\right)}. \end{aligned}$$

Так как $\sum_{i=1}^n X_i \sim \text{Pois}(\lambda n)$ получаем, что

$$P(X = \bar{x} | T(X) = t) = \frac{\prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}}{\frac{(n\lambda)^t}{t!} e^{-n\lambda}}$$

Так как $\prod_{i=1}^n \lambda^{x_i} e^{-\lambda} = \lambda^t e^{-n\lambda}$, то все выражения с параметром λ сокращаются. Таким образом искомая условная вероятность не зависит от λ и статистика $T(X)$ является достаточной.

Теорема 6.3 (Критерий факторизации). Для того, чтобы статистика $T = T(X)$ была достаточной, необходимо и достаточно, чтобы функция правдоподобия $L(\bar{x}; \theta)$ имела следующий вид:

$$L(\bar{x}; \theta) = g(T(\bar{x}); \theta) \cdot h(\bar{x}),$$

где g и h — неотрицательные функции, и функция h не зависит от θ .

Доказательство. Если статистика T достаточна, то для любого t из области значений $T(X)$ функция $L(\bar{x}|t; \theta)$ не зависит от θ и ее можно записать в виде $h(\bar{x}; t)$.

Пусть $P_\theta(T(X) = t) = g(t; \theta)$ и $T(\bar{x}) = t$. Тогда событие $\{X = \bar{x}\} \subseteq \{T(X) = t\}$, поэтому

$$\begin{aligned} L(\bar{x}; \theta) &= P_\theta(X = \bar{x}) = P_\theta(X = \bar{x}, T(X) = t) = \\ &= P_\theta(T(X) = t) \cdot P_\theta(X = \bar{x} | T(X) = t) = g(t; \theta) \cdot L(\bar{x}|t; \theta) = g(t; \theta) \cdot h(\bar{x}; t). \end{aligned}$$

Доказательство в обратную сторону проведем только для дискретной модели. Пусть имеет место разложение (факторизация). Тогда для любого \bar{x} такого, что $T(\bar{x}) = t$ верно:

$$\begin{aligned} L(\bar{x}|t; \theta) &= P_\theta(X = \bar{x} | T(X) = t) = \frac{P_\theta(X = \bar{x}, T(X) = t)}{P_\theta(T(X) = t)} = \\ &= \frac{L(\bar{x}; \theta)}{\sum_{\bar{x}: T(\bar{x})=t} L(\bar{x}; \theta)} = \frac{g(T(\bar{x}); \theta) \cdot h(\bar{x})}{\sum_{\bar{x}} g(T(\bar{x}); \theta) \cdot h(\bar{x})} = \frac{h(\bar{x})}{\sum_{\bar{x}} h(\bar{x})} \end{aligned}$$

— не зависит от θ . □

Следствие 6.4. Эффективная оценка является достаточной.

Доказательство. Пользуясь доказанной теоремой Рао-Крамера:

$$T(\bar{x}) - \tau(\theta) = a(\theta) \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta}.$$

Так как:

$$\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} = \frac{1}{L(\bar{x}; \theta)} \cdot \frac{\partial L(\bar{x}; \theta)}{\partial \theta},$$

то

$$L(\bar{x}; \theta) = \frac{a(\theta) \frac{\partial L(\bar{x}; \theta)}{\partial \theta}}{T(\bar{x}) - \tau(\theta)}.$$

Для завершения доказательства осталось ввести следующие обозначения:

$$\frac{a(\theta)}{T(\bar{x}) - \tau(\theta)} = g(T(\bar{x}); \theta),$$

$$\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} = h(\bar{x}).$$

□

Следствие 6.5. Если $T = T(X)$ — достаточная статистика параметра $\tau(\theta)$, то о.м.п. является функцией от T .

Доказательство.

$$\hat{Q}(x) = \arg \max_{\theta} L(\bar{x}; \theta) = \arg \max_{\theta} g(T(\bar{x}); \theta) h(x) = \arg \max_{\theta} g(T(\bar{x}); \theta).$$

□

Пример 6.6 (Равномерная модель и достаточная статистика для нее). Пусть $X = (X_1, \dots, X_n)$ — выборка из равномерного распределения $R(0, \theta)$. Выпишем плотность равномерного распределения:

$$f_{\theta}(x) = \theta^{-1} \text{Ind}(0 \leq x \leq \theta)$$

и найдем плотность X как случайного вектора:

$$L(\bar{x}; \theta) = \prod_{i=1}^n f_{\theta}(x_i) = \theta^{-n} \prod_{i=1}^n \text{Ind}(0 \leq x_i \leq \theta) = \theta^{-n} \text{Ind}(x_{(n)} \leq \theta) \text{Ind}(x_{(1)} \geq 0).$$

Отсюда следует, что в данном случае достаточной статистикой является максимальное значение выборки $X_{(n)}$.

Теорема 6.7 (Рао-Блекуэлла-Колмогорова). Оптимальная оценка, если существует, является функцией от достаточной статистики.

Доказательство. Пусть $T = T(X)$ — достаточная статистика, T_1 — произвольная несмещенная оценка заданной параметрической функции (она существует по условию теоремы).

Рассмотрим функцию

$$H(t) = \mathbf{M}_{\theta}(T_1 | T = t) = \int_B T_1(\bar{x}) \cdot L(\bar{x} | t; \theta) d\bar{x}.$$

Эта функция не зависит от θ , так как условная плотность $L(\bar{x}|t; \theta)$ не зависит от параметра θ . Докажем, что $H(T(X))$ будет являться несмещенной оценкой для $\tau(\theta)$. Действительно, пользуясь следствием 5.3:

$$\mathbf{M}(H(T(X))) = \mathbf{M}(\mathbf{M}(T|T_1)) = \mathbf{M}(T_1) = \tau(\theta).$$

Покажем, что

$$\mathbf{D}_\theta(H(T)) \leq \mathbf{D}_\theta(T_1), \forall \theta,$$

причем равенство имеет место в том и только в том случае, когда $T_1 = H(T)$. Для доказательства заметим, что

$$\begin{aligned} \mathbf{D}_\theta(T_1) &= \mathbf{M}_\theta(T_1 - \tau(\theta) + H(T) - H(T))^2 = \\ &= \mathbf{M}_\theta[(T_1 - H(T))^2 + 2\mathbf{M}_\theta[(T_1 - H(T))(H(T) - \tau(\theta))] + \mathbf{M}_\theta[-\tau(\theta) - H(T)]^2] = \\ &= \mathbf{M}_\theta[T_1 - H(T)]^2 + D(H(T)) \geq \mathbf{D}(H(T)), \end{aligned}$$

поскольку в силу следствия 5.3

$$\begin{aligned} \mathbf{M}_\theta[(T_1 - H(T))(H(T) - \tau(\theta))] &= \mathbf{M}_\theta[H(T) \cdot (T_1 - H(T))] = \\ &= \mathbf{M}_\theta \mathbf{M}_\theta[H(T) \cdot (T_1 - H(T))|T] = \mathbf{M}_\theta[H(T) \cdot \mathbf{M}_\theta(T_1 - H(T)|T)] = \\ &= \mathbf{M}_\theta[H(T) \cdot (\mathbf{M}_\theta(T_1|T) - H(T))] = 0 \end{aligned}$$

Таким образом, для любой несмещенной оценки функции $\tau(\theta)$, не являющейся функцией от достаточной статистики, всегда можно указать несмещенную оценку, которая зависит от достаточной статистики и имеет дисперсию меньшую, чем исходная оценка. Следовательно, оптимальную оценку надо искать среди функций от достаточной статистики. □

Определение 6.8. Достаточная статистика $T = T(X)$ называется *полной*, если для любой функции φ из того, что

$$\mathbf{M}_\theta \varphi(T) = 0$$

следует, что $\varphi \equiv 0$ на всем множестве значений статистики T .

Теорема 6.9. Если существует полная достаточная статистика, то произвольная функция от нее будет являться оптимальной оценкой своего математического ожидания.

Доказательство. Пусть $T = T(X)$ — полная достаточная статистика и $H(T)$ — произвольная функция от T . Обозначим

$$\mathbf{M}_\theta(H(T)) = \tau(\theta),$$

и покажем, что $H(T)$ — единственная функция от T с математическим ожиданием $\tau(\theta)$.

Предположим противное — пусть $H_1(T)$ — другая такая функция, тогда

$$\mathbf{M}(H_1(T) - H(T)) = 0, \forall \theta,$$

т.к. T — полная статистика. Значит $H_1(T) = H(T)$.

По теореме 6.7 оптимальную оценку для $\tau(\theta)$ необходимо искать в классе функций, зависящих от T . Но $H(T)$ — единственная функция от T , несмещенно оценивающая $\tau(\theta)$ и она является искомой оптимальной оценкой. \square

Пример 6.10. Пусть $X = (X_1, \dots, X_n)$ — выборка из равномерного распределения $R(0, \theta)$. Из примера 6.6 известно, что $T(X) = X_{(n)}$ является достаточной статистикой. Покажем, что $T(X)$ является полной.

Пусть φ такова, что

$$\mathbf{M}_\theta \varphi(T(X)) \equiv 0, \forall \theta \in (0, \infty).$$

Выпишем плотность статистики $T(x)$:

$$f_{X_{(n)}}(y) = \frac{\partial}{\partial y} F_{X_{(n)}}(y) = \begin{cases} \frac{ny^{n-1}}{\theta^n}, & y \in [0, \theta] \\ 0, & \text{иначе.} \end{cases}$$

Тогда:

$$\mathbf{M}_\theta \varphi(X_{(n)}) = \int_0^\theta \varphi(y) \frac{ny^{n-1}}{\theta^n} dy \equiv 0 \Rightarrow \int_0^\theta \varphi(y) y^{n-1} dy \equiv 0.$$

Продифференцируем последнее равенство по θ :

$$\varphi(\theta)\theta^{n-1} \equiv 0,$$

отсюда следует, что

$$\varphi(\theta) \equiv 0 \quad \forall \theta \in (0, \infty).$$

Доказали полноту.

Согласно теореме 6.9 она является оптимальной статистикой для своего математического ожидания:

$$M_{\theta} X_{(n)} = \int_{\mathbb{R}} y f_{X_{(n)}}(y) dy = \frac{n}{n+1} \theta.$$

Отсюда следует, что $X_{(n)}$ является смещенной оценкой θ . Найдем оптимальную оценку для θ . По теореме 6.9 необходимо найти такую функцию H , что $M_{\theta} H(T) = \theta$. Очевидно, что такая функция

$$H(x) = \frac{n+1}{n} x.$$

Таким образом, оценка

$$\hat{\theta} = \frac{n+1}{n} X_{(n)}$$

является оптимальной оценкой параметра θ .

Найдем дисперсию $X_{(n)}$:

$$M_{\theta} X_{(n)}^2 = \int_{\mathbb{R}} y^2 f_{X_{(n)}}(y) dy = \frac{n\theta^2}{n+2}.$$

Откуда

$$D X_{(n)} = \frac{n\theta^2}{(n+2)(n+1)^2}.$$

А

$$D \hat{\theta} = \frac{\theta^2}{(n+2)n}.$$

Если бы выполнялись условия регулярности (см. пример 4.22) и $\hat{\theta}$ являлась бы регулярной оценкой, то ее дисперсия была бы ограничена снизу величиной $(ni(\theta))^{-1}$, которая имеет порядок малости n^{-1} . Полученная выше

оценка имеет порядок малости n^{-2} . Такие оценки иногда называют *сверхэффективными*.

Задача 6.11. Показать, что в случае $X = (X_1, \dots, X_n)$ — выборка из равномерного распределения $R(0, \theta)$, оценка $2\bar{X}$ является несмещенной и найти условия, когда она является оптимальной оценкой.

Резюмируем все вышесказанное. Пусть в рассматриваемом семействе $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ существует полная и достаточная статистика T и требуется оценить параметрическую функцию $\tau(\theta)$. Тогда:

- если существует какая-то несмещенная оценка $\tau(\theta)$, то существует и несмещенная оценка, являющаяся функцией от T (в противном случае класс несмещенных оценок пуст);
- оптимальная оценка, когда она существует, всегда является функцией от T и определяется уравнением $M_\theta(H(T)) = \tau(\theta)$;
- оптимальную оценку можно искать по формуле

$$H(T) = M_\theta(T_1|t),$$

исходя из любой несмещенной оценки T_1 функции $\tau(\theta)$. (Однако это используется редко в виду значительных аналитических сложностей вычисления условного математического ожидания).

Пример 6.12. Ранее, в примере 6.2 было показано, что статистика $T(X) = \sum_{i=1}^n X_i$ является достаточной статистикой в случае, когда распределение из $\mathcal{L}(\xi)$, $\xi \sim \text{Pois}(\theta)$. Покажем, что она является полной. Напомним, что $T(X) \sim \text{Pois}(n\theta)$. Пусть

$$M_\theta \varphi(T(X)) = \sum_{k=0}^{\infty} \varphi(k) \exp\{-n\theta\} \frac{(n\theta)^k}{k!} = 0 \quad \forall \theta \in \Theta.$$

Рассмотрим последнее выражение при $\theta = 0$. Так как $M_\theta \varphi(T(X)) = \varphi(0)$, то $\varphi(0) = 0$.

Умножим последнее выражение на θ^{-1} и устремим θ к 0 и получим, что $\varphi(1) = 0$. Аналогично получим, что $\varphi(x) = 0$, $x \geq 2$. Таким образом показали, что $\varphi \equiv 0$.

Приведем без доказательства следующую теорему.

Теорема 6.13 (О полноте экспоненциальных семейств). Пусть $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$ — экспоненциальное семейство, определенное в 4.21, и функция $A(\theta)$ и параметрическое пространство Θ таковы, что $A(\theta)$ содержит некоторый отрезок, когда θ пробегает множество Θ . Тогда $T(X) = B(X)$ является полной и достаточной статистикой.

Пример 6.14. Пусть $X = (X_1, \dots, X_n)$ — выборка из гамма-распределения $\Gamma(\frac{1}{\theta}, 1)$. Покажем, что

$$T(X) = \frac{n}{n+1} \bar{X}^2$$

является оптимальной оценкой θ^2 .

Выпишем функцию правдоподобия:

$$L(X; \theta) = \frac{1}{\theta^n} \exp\left\{-\frac{n}{\theta} \bar{X}\right\}.$$

По теореме о полноте экспоненциальных семейств \bar{X} — полная и достаточная статистика, поэтому любая измеримая функция от \bar{X} является оптимальной оценкой своего математического ожидания. В частности, $T(X)$ оптимальная оценка для

$$\begin{aligned} M_\theta(T(X)) &= \frac{n}{n+1} M_\theta \bar{X}^2 = \frac{n}{n+1} \left(D_\theta \bar{X} + (M_\theta \bar{X})^2 \right) = \\ &= \frac{n}{n+1} \left(\frac{1}{n} D_\theta X_1 + (M_\theta X_1)^2 \right) = \frac{n}{n+1} \left(\frac{\theta^2}{n} + \theta^2 \right) = \theta^2. \end{aligned}$$

6.2 Модели с выборочным пространством, зависящем от параметра θ

Пусть $a \in \mathbb{R}$, $X = (X_1, \dots, X_n)$ из параметрического семейства $\mathcal{F} = \{F_\theta, \theta \in \mathbb{R}, \theta > a\}$, при этом плотность случайных величин из рассматриваемых семейств равна:

$$f_\theta(x) = \begin{cases} Q_1(\theta) M_1, & x \in [a, \theta) \\ 0, & x \notin [a, \theta) \end{cases}$$

Где функция $Q_1 \geq 0$ для всех $\theta > a$ и дифференцируема.

Найдем ограничение на вид функции M_1 :

$$1 = \int_a^\theta f_\theta(x) dx = \int_a^\theta Q_1(\theta) M_1(x) dx = Q_1(\theta) \int_a^\theta M_1(x) dx \Rightarrow$$

$$\Rightarrow \frac{1}{Q_1(\theta)} = \int_a^\theta M_1(x) dx. \quad (3)$$

Возьмем производную от обеих частей (3):

$$-\frac{Q_1'(\theta)}{Q_1^2(\theta)} = M_1(\theta). \quad (4)$$

Найдем достаточную статистику. Пусть \bar{x} — реализация выборки нашего распределения, тогда функция правдоподобия равна:

$$L(\bar{x}; \theta) = \prod_{i=1}^n f_\theta(x_i) = Q_1^n(\theta) \prod_{i=1}^n (M_1(x_i) \text{Ind}(a \leq x_i \leq \theta)) =$$

$$= Q_1^n(\theta) \prod_{i=1}^n (M_1(x_i) \text{Ind}(x_{(1)} \geq a) \text{Ind}(x_{(n)})).$$

Воспользуемся критерием факторизации для того, чтобы найти достаточную статистику:

$$L(\bar{x}, \theta) = g(T(x); \theta) h(x)$$

То есть $T(x) = x_{(n)}$ — достаточная статистика.

Воспользуемся (3) и найдем ее функцию распределения:

$$F_{x_{(n)}}(y) = P(x_{(n)} \leq y) =$$

$$= \prod_{i=1}^n (P(x_i \leq y)) = P^n(x_1 \leq y) = \left(\int_a^y Q_1(\theta) M_1(x) dx \right)^n =$$

$$= Q_1^n(\theta) \left(\frac{1}{Q_1(y)} \right)^n = \left(\frac{Q_1(\theta)}{Q_1(y)} \right)^n.$$

Откуда с использованием (4) получим выражение для плотности:

$$f_{x_{(n)}}(y) = \frac{-n Q_1(\theta)^n Q_1'(\theta)}{Q_1(y)^{n-1}} = Q_1^n(\theta) n Q_1(y)^{(-n-1)} M_1(y) Q_1^2(y).$$

Зная плотность, можем проверить полноту. Для этого необходимо доказать, что из

$$\int_a^\theta \varphi(y) f_{x_{(n)}}(y) dy = 0$$

следует, что $\varphi(y) \equiv 0$. Действительно:

$$\int_a^\theta \varphi(y) Q_1^n(\theta) n Q_1(y)^{(-n-1)} M_1(y) Q_1^2(y) dy = 0,$$

откуда:

$$\int_a^\theta \varphi(y) Q_1(y)^{(-n+1)} M_1(y) dy = 0$$

Возьмем производную от левой и правой части:

$$\varphi(\theta) Q_1(\theta)^{(-n+1)} M_1(\theta)$$

Значит $\varphi(\theta) \equiv 0$ и статистика $T(x) = X_{(n)}$ полная. Тогда для любой функции H статистика $H(x_{(n)})$ будет оптимальной статистикой своего математического ожидания:

$$\int_a^\theta H(t) g(t, \theta) dt = \tau(\theta).$$

Предполагая дифференцируемость функции τ найдем выражение для $H(x)$:

$$\begin{aligned} \int_a^\theta H(y) n Q_1(\theta)^n Q_1(y)^{-n+1} M_1(y) dy &= \tau(\theta) \Rightarrow \\ \Rightarrow n \int_a^\theta H(y) Q_1(y)^{-n+1} M_1(y) dy &= \frac{\tau(\theta)}{Q_1(\theta)^n} \Rightarrow \\ \Rightarrow n H(\theta) Q_1(\theta)^{-n+1} M_1(\theta) &= \frac{\tau'(\theta) Q_1(\theta)^n - n Q_1(\theta)^{n-1} \tau(\theta)}{Q_1(\theta)^{2n}}. \end{aligned}$$

Воспользуемся (4):

$$\begin{aligned} H(\theta) &= \frac{\tau(\theta)' Q(\theta) - n \tau(\theta) Q_1'(\theta)}{n Q_1(\theta)^{n+1} Q_1(\theta)^{-n+1} M_1(\theta)} \\ H(\theta) &= \frac{\tau(\theta)' Q(\theta) - n \tau(\theta) Q_1'(\theta)}{n Q_1(\theta)^2} M_1(\theta) = \tau(\theta) + \frac{\tau'(\theta)}{n Q_1(\theta) M_1(\theta)}. \end{aligned}$$

Или:

$$H(\theta) = \tau(\theta) + \frac{\tau'(\theta)}{nf_{\theta}(\theta)}$$

Пусть дана выборка из распределения $\mathcal{R}[0; \theta)$. Найдем оптимальную оценку для параметрической функции $\tau(\theta) = \theta^r$. В этом случае $Q_1(\theta) = \theta^{-1}$, $M_1(x) = 1$ и оптимальной оценкой для θ^r является:

$$X_{(n)}^r + \frac{r}{n}X_{(n)}^r.$$

Заметим, что для случая $r = 1$ эта оценка ранее была получена нами.

Используя аналогичные рассуждения можно показать, что в случае, когда

$$f_{\theta}(x) = Q_2(\theta) \cdot M_2(x), \theta \leq x \leq b,$$

для некоторого фиксированного b . В этом случае оптимальной оценкой произвольной дифференцируемой функции $\tau(\theta)$ является статистика:

$$\tau \left(X_{(1)} - \frac{\tau'(X_{(1)})}{n \cdot f_{X_{(1)}}(X_{(1)})} \right).$$

7 Асимптотические свойства оценки максимального правдоподобия.

Пусть здесь и далее $X = (X_1, X_2, \dots, X_n)$ — некоторая выборка из распределения $\mathcal{L}(X_i) \sim \xi$, $\bar{x} = (x_1, x_2, \dots, x_n)$ — реализация выборки.

Определение 7.1. Пусть имеется последовательность случайных величин $\{\xi_n\}_{n \geq 1}$, и при $n \rightarrow \infty$ $\xi_n \rightarrow \xi$ по распределению, $\xi \sim \mathcal{N}(\mu, \sigma^2)$. Тогда будем говорить, что случайная величина ξ_n асимптотически нормальна с параметрами μ_n, σ_n^2 .

Определение 7.2. Пусть $T_n(X)$ является оценкой параметра $\tau(\theta)$, пусть также T_n — асимптотически нормальная с параметрами $\tau(\theta), \frac{\sigma^2(\theta)}{n}$ (иными словами $L(T_n; \theta) \rightarrow \mathcal{N}\left(\tau(\theta), \frac{\sigma^2(\theta)}{n}\right)$).

Асимптотической эффективностью такой оценки будем называть величину

$$\varepsilon_0(T_n, \theta) = \frac{[\tau'(\theta)]^2}{i(\theta)\sigma^2(\theta)}.$$

Оценку будем называть асимптотически эффективной, если $\varepsilon_0(T_n; \theta) = 1$.

Теорема 7.3. Пусть выполнены следующие условия:

1. $\theta \in \Theta$, Θ — невырожденный замкнутый интервал на \mathbb{R} .
2. Существуют производные:

$$\frac{\partial \ln f_\theta(x)}{\partial \theta}, \frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2}, \frac{\partial^3 \ln f_\theta(x)}{\partial \theta^3} \quad \forall \theta \in \Theta.$$

3. Для всех $\theta \in \Theta$ существуют интегрируемые на \mathbb{R} функции H_1 , H_2 и функция H , такая, что:

$$M_\theta H = \int_{\mathbb{R}} H(x) f_\theta(x) dx < M,$$

где не зависит от θ и

$$\left| \frac{\partial \ln f_\theta(x, \theta)}{\partial \theta} \right| \leq H_1(x),$$

$$\left| \frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2} \right| \leq H_2(x),$$

$$\left| \frac{\partial^3 \ln f_\theta(x)}{\partial \theta^3} \right| \leq H(x).$$

То есть, все три производные ограничены по x .

$$4. \quad 0 < i(\theta) = \int_{\mathbb{R}} \left(\frac{\partial \ln L(\bar{x}, \theta)}{\partial \theta} \right)^2 L(\bar{x}, \theta) dx < \infty.$$

Тогда оценка максимального правдоподобия обладает следующими свойствами:

1. Такая оценка состоятельна;
2. Такая оценка асимптотически нормальна;
3. Такая оценка асимптотически эффективна.

Условие теоремы содержит в себе условие регулярности. Таким образом, везде далее считаем, что рассматриваемая модель регулярна.

Лема 7.4. Пусть

$$B_0 = \frac{1}{n} \sum_{i=1}^n \left(\frac{\partial \ln f_\theta(x_i)}{\partial \theta} \right) \Bigg|_{\theta=\theta_0},$$

$$B_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{\partial^2 \ln f_\theta(x_i)}{\partial \theta^2} \right) \Big|_{\theta=\theta_0},$$

$$B_2 = \frac{1}{n} \sum_{i=1}^n H(x_i).$$

Тогда

1. $B_0 \xrightarrow[n \rightarrow \infty]{P} 0,$
2. $B_1 \xrightarrow[n \rightarrow \infty]{P} -k^2, \text{ где } k^2 = i(\theta),$
3. $B_2 \xrightarrow[n \rightarrow \infty]{P} M(H(x_1)) < M.$

Доказательство. Все выражения B_j является суммой независимых одинаково распределенных случайных величин с конечным математическим ожиданием. Воспользуемся законом больших чисел:

$$\frac{1}{n} \sum \xi_i \xrightarrow[n \rightarrow \infty]{P} M \xi$$

Поэтому, в частности, очевидно, что $B_2 \xrightarrow[n \rightarrow \infty]{P} M(H(x_1)) < M.$

Докажем лемму для B_0 . В условиях регулярности можем менять пределы интегрирования и дифференцирования:

$$\begin{aligned} M \frac{\partial \ln f_\theta(\xi)}{\partial \theta} &= \int_{\mathbb{R}} \frac{\partial \ln f_\theta(x)}{\partial \theta} f_\theta(x) dx = \\ &= \int_{\mathbb{R}} \frac{1}{f_\theta(x)} \frac{\partial f_\theta(x)}{\partial \theta} f_\theta(x) dx = \frac{\partial}{\partial \theta} \int_{\mathbb{R}} f_\theta(x) dx = \frac{\partial}{\partial \theta} 1 = 0. \end{aligned}$$

Докажем лемму для B_1 :

$$\begin{aligned}
\mathbb{M} \frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2} &= \int_{\mathbb{R}} \frac{\partial}{\partial \theta} \left(\frac{\partial \ln f_\theta(x)}{\partial \theta} \right) f_\theta(x) dx = \int_{\mathbb{R}} \frac{\partial}{\partial \theta} \left(\frac{1}{f_\theta(x)} \frac{\partial f_\theta(x)}{\partial \theta} \right) f_\theta(x) dx = \\
&= \int_{\mathbb{R}} \frac{(-1)}{f_\theta^2(x)} \left(\frac{\partial f_\theta(x)}{\partial \theta} \right)^2 f_\theta(x) dx + \int_{\mathbb{R}} \frac{\partial^2 f_\theta(x)}{\partial \theta^2} \frac{1}{f_\theta(x)} f_\theta(x) dx = \\
&= - \int_{\mathbb{R}} \frac{1}{f_\theta(x)} \left(\frac{\partial f_\theta(x)}{\partial \theta} \right)^2 dx + \underbrace{\frac{\partial^2}{\partial \theta^2} \int_{\mathbb{R}} f_\theta(x) dx}_{=0} = \\
&= - \int_{\mathbb{R}} \left(\frac{\partial \ln f_\theta(x)}{\partial \theta} f_\theta(x) \right)^2 \frac{1}{f_\theta(x)} = \\
&= - \int_{\mathbb{R}} \left(\frac{\partial \ln f_\theta(x)}{\partial \theta} \right)^2 f_\theta(x) dx = -i(\theta) = -k^2.
\end{aligned}$$

□

Лема 7.5 (без доказательства). Пусть X_n, Y_n, Z_n — последовательности случайных величин такие, что:

1. $X_n \xrightarrow[n \rightarrow \infty]{d} X, Y_n \xrightarrow[n \rightarrow \infty]{P} 0$, тогда $X_n + Y_n \xrightarrow[n \rightarrow \infty]{d} X$,
2. $X_n \xrightarrow[n \rightarrow \infty]{d} X, Z_n \xrightarrow[n \rightarrow \infty]{P} 1$, тогда $X_n \cdot Z_n \xrightarrow[n \rightarrow \infty]{d} X; X_n/Z_n \xrightarrow[n \rightarrow \infty]{d} X$.

Доказательство. Пользуясь данными леммами, докажем теорему. Разложим в ряд Тейлора с остаточным членом в форме Лагранжа плотность распределения:

$$\begin{aligned}
\frac{\partial \ln f_\theta(x)}{\partial \theta} &= \frac{\partial \ln f_\theta(x)}{\partial \theta} \Big|_{\theta=\theta_0} + \frac{\partial^2 \ln f_\theta(x)}{\partial \theta^2} \Big|_{\theta=\theta_0} (\theta - \theta_0) + \\
&\quad + \frac{1}{2} \frac{\partial^3 \ln f_\theta(x)}{\partial \theta^3} \Big|_{\theta=\theta^*} (\theta - \theta_0)^2,
\end{aligned}$$

где θ^* лежит между θ_0 и θ .

Можно показать, что существует $0 \leq \tau \leq 1$ такое, что

$$\frac{1}{2} \frac{\partial^3 \ln f_\theta(x)}{\partial \theta^3} \Big|_{\theta=\theta^*} (\theta - \theta_0)^2 = \frac{1}{2} \tau H(\xi) (\theta - \theta_0)^2.$$

Пусть

$$A(\theta) = \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} = \frac{1}{n} \sum_{i=1}^n \left(\frac{\partial \ln f_{\theta}(x_i)}{\partial \theta} \right).$$

Тогда $A(\theta) = B_0 + (\theta - \theta_0)B_1 + \frac{1}{2}\tau(\theta - \theta_0)^2 B_2$.

Для нахождения оценки максимального правдоподобия необходимо решить уравнение

$$\frac{1}{n} \frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} = 0$$

относительно θ .

Фиксируем $\varepsilon > 0$, $\delta > 0$ — некоторые достаточно малые числа и выберем $n > n_0(\varepsilon; \delta)$ так, что выполнены следующие неравенства (по условию леммы 7.4 это возможно):

- $P(|B_0| \geq \delta^2) < \frac{\varepsilon}{3}$,
- $P(|B_1| \geq \frac{k^2}{2}) < \frac{\varepsilon}{3}$,
- $P(|B_2| \geq 2M) < \frac{\varepsilon}{3}$.

Рассмотрим событие:

$$S = \left\{ x : |B_0| < \delta^2, B_1 < -\frac{k^2}{2}, |B_2| < 2M \right\}.$$

Тогда, при $n > n_0 : P(S) > 1 - \varepsilon$.

Пусть $x \in S$. Рассмотрим $\theta \in [\theta_0 - \delta; \theta_0 + \delta]$: Оценим $A(\theta)$:

$$\left| B_0 + \frac{1}{2}\tau\delta^2 B_2 \right| \leq \delta^2 \left(\frac{1}{2}M + 1 \right).$$

Тогда так как $\theta \in [\theta_0 - \delta; \theta_0 + \delta]$:

$$A(\theta) = B_0 + \delta B_1 + \frac{1}{2}\tau\delta^2 B_2.$$

В этом случае знак $A(\theta)$ определяется слагаемым $B_1\delta$.

Тогда $A(\theta) \in (\theta_0 - \delta; \theta_0 + \delta)$ и точка максимума θ^* с вероятностью не меньшей $1 - \varepsilon$ будет лежать в интервале $(\theta_0 - \delta; \theta_0 + \delta)$, а это как раз и показывает состоятельность оценки.

Покажем асимптотическую нормальность. $A(\theta^*) = 0$, тогда:

$$\theta^* - \theta_0 = \frac{B_0}{-B_1 - \frac{1}{2}\tau(\theta^* - \theta_0)B_2},$$

откуда

$$\frac{\theta^* - \theta_0}{\frac{1}{\sqrt{nk^2}}} = \frac{\frac{1}{\sqrt{nk^2}} \sum_{i=1}^n \frac{\partial \ln f_\theta(X_i)}{\partial \theta}}{-\frac{B_1}{k^2} + \frac{1}{2} \tau \frac{\theta^* - \theta_0}{k^2} B_2}.$$

Введем случайную величину: $Y_i = \frac{\partial \ln f(X_i)}{\partial \theta}$, при этом

$$\mathbf{M} Y_i = 0, \mathbf{D} Y_i - \mathbf{M} Y_i = k^2.$$

Используя центральную предельную теорему:

$$\frac{1}{\sqrt{nk^2}} \sum \frac{\partial \ln f(X_i)}{\partial \theta} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, 1)$$

Пользуясь леммой 7.4:

$$B_1 \xrightarrow[n \rightarrow \infty]{P} -k^2,$$

$$B_2 \xrightarrow[n \rightarrow \infty]{P} \mathbf{M}(H(\xi_1)) < M \Rightarrow \frac{1}{2} \tau \frac{\theta^* - \theta_0}{k^2} B_2 \leq \frac{1}{2} \frac{M}{k^2} (\theta^* - \theta_0) \rightarrow 0, (\theta^* - \theta_0) < \delta \rightarrow 0,$$

получаем:

$$\frac{B_1}{-k^2} + \frac{1}{2} \tau \frac{\theta^* - \theta_0}{k^2} B_2 \xrightarrow[n \rightarrow \infty]{P} 1, \text{ при } \delta \rightarrow 0.$$

Используя лемму 7.5, получаем доказательство асимптотической нормальности.

Отсюда следует, что $\sqrt{nk^2}(\theta^* - \theta_0)$ асимптотически нормальна с $\mathcal{N}(0, 1)$, а θ^* — с параметрами $\mathcal{N}(\theta_0, \frac{1}{nk^2})$.

Дисперсия $nk^2 = i_n(\theta)$, что доказывает эффективность оценки.

□

8 Асимптотически доверительный интервал.

Пусть заданы $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$. Ранее мы занимались построением точечных оценок неизвестного параметра $\tau(\theta)$. Такие оценки могут быть не очень интересны с практической точки зрения (например в непрерывных распределениях, когда вероятность конкретной точки всегда равна 0). В данном разделе рассмотрим иной подход, основная идея которого заключается в построении доверительного множества, в котором с повышенной вероятностью лежит оцениваемый параметр.

Определение 8.1. Будем называть γ -доверительным интервалом параметрической функции $\tau(\theta)$ такой случайный интервал $(T_1(x), T_2(x))$, $T_1(x) < T_2(x)$, который удовлетворяет условию:

$$P_{\theta}(T_1(x) < \tau(\theta) < T_2(x)) \geq \gamma \quad \forall \theta \in \Theta.$$

В данном курсе рассмотрим только так называемые асимптотические доверительные интервалы.

Пусть имеется асимптотически нормальная оценка $T_n = T_n(X)$ для параметра $\tau(\theta)$. То есть иными словами: пусть при $n \rightarrow \infty$ имеет место соотношение:

$$\mathcal{L}_{\theta}(\sqrt{n}(T_n - \tau(\theta))) \rightarrow N(0, \sigma_n^2(\theta)) \quad \forall \theta \in \Theta,$$

причем $\sigma_n^2(\theta)$ непрерывна по θ . Тогда

$$\mathcal{L}_{\theta}\left(\frac{\sqrt{n}(T_n - \tau(\theta))}{\sigma_n(\theta)}\right) \rightarrow N(0, 1).$$

Для стандартного нормального распределения легко показать, что для заданной вероятности интервал минимальной длины будет иметь вид $(-t, t)$. Построим такой интервал:

$$\begin{aligned} P\left(\sqrt{n} \cdot \left|\frac{T_n - \tau(\theta)}{\sigma_n(\theta)}\right| < c_{\gamma}\right) &= P\left(\tau(\theta) \in \left(T - \frac{c_{\gamma}\sigma_n(\theta)}{\sqrt{n}}, T + \frac{c_{\gamma}\sigma_n(\theta)}{\sqrt{n}}\right)\right) = \\ &= \Phi(c_{\gamma}) - \Phi(-c_{\gamma}) = 2\Phi(c_{\gamma}) - 1 = \gamma, \end{aligned}$$

где Φ - функция распределения случайной величины, имеющей стандартное нормальное распределение.

!!!!!!!Добавить классный пример про доверительный интервал для параметра бернулиевской модели (стр 285)

9 Проверка статистических гипотез

9.1 Основные понятия

Одним из основных направлений математической статистики является теория проверки статистических гипотез. Неформально статистическую гипотезу можно понимать как некоторое предположение о виде или параметрах

распределения. Необходимо уметь подтверждать или опровергать гипотезы о виде распределения, о зависимости данных, об однородности выборок и многие другие.

Пусть как и ранее X — выборка, \mathfrak{X} — выборочное пространство, \mathcal{F} — совокупность априори доступных распределений выборки X .

Задачу проверки статистических гипотез можно сформулировать следующим образом. Дана выборка X из неизвестного распределения $F_X \in \mathcal{F}$. Выделим подмножество $\mathcal{F}_0 \subset \mathcal{F}$, где \mathcal{F}_0 . По реализации выборки X необходимо проверить справедливо ли утверждение:

$$F_X \in \mathcal{F}_0$$

или ложно, то есть верно, что

$$F_X \in \mathcal{F}_1, \mathcal{F}_1 = \mathcal{F} \setminus \mathcal{F}_0.$$

При этом говорят о проверке гипотез.

- гипотеза H_0 — основная гипотеза (нулевая гипотеза), заключается в том, что $F_X \in \mathcal{F}_0$;
- гипотеза H_1 — альтернативная гипотеза, заключается в том, что $F_X \in \mathcal{F}_1$.

Если определены гипотезы H_0 и H_1 , то говорят о *проверке гипотезы H_0 против альтернативы H_1* .

Определение 9.1. Если множество \mathcal{F}_0 состоит из одного распределения, то говорят, что H_0 — простая гипотеза, иначе H_0 — сложная гипотеза.

Определение 9.2. Если множество \mathcal{F}_1 состоит из одного распределения, то говорят, что H_1 — простая гипотеза, иначе H_1 — сложная гипотеза.

Пример 9.3. Пусть $\mathcal{F} \in \{\mathcal{N}(\mu, \sigma^2), \mu, \sigma \in \mathbb{R}\}$. В качестве примера простой основной гипотезы $H_0: F_X = \mathcal{N}(0, 1)$, и сложной альтернативы $H_1: F_X \neq \mathcal{N}(0, 1)$.

Пример 9.4. Пример простой основной и альтернативной гипотезы: $\mathcal{F} = \{\mathcal{N}(0, 1), \mathcal{N}(1, 1)\}$, то $H_0: F_X = \mathcal{N}(0, 1)$ и $H_1: F_X = \mathcal{N}(1, 1)$.

Определение 9.5. Статистический критерий — это правило, по которому каждой реализации выборки ставится в соответствие решение: принимаем гипотезу H_0 или отвергаем ее (то есть принимаем гипотезу H_1).

Определение 9.6. Иногда альтернативу H_1 не конкретизируют, то есть задана только гипотеза H_0 (множество распределений \mathcal{F}_0). В этом случае говорят о согласии данных X с нулевой гипотезой. Такой критерий называется критерием согласия.

Пример 9.7. Примеры критериев согласия:

- выборка X из распределения Пуассона: $H_0: F_X \in \{\text{Pois}(\lambda), \lambda > 0\}$,
- выборка X из распределения Пуассона с параметром λ_0 : $H_0: F_X = \text{Pois}(\lambda_0)$.

Зачастую множество распределений \mathcal{F} есть некоторое параметрическое семейство:

$$\mathcal{F} = \{F_\theta, \theta \in \Theta\}.$$

Тогда основную и альтернативную гипотезы можно определить следующим образом:

- гипотеза $H_0: \theta \in \Theta_0 \subset \Theta$;
- гипотеза $H_1: \theta \in \Theta_1, \Theta_1 = \Theta \setminus \Theta_0$.

В данном случае говорят о *параметрических гипотезах* и *параметрических критериях*.

Говоря о критерии, подразумеваем некоторое правило, согласно которому по каждому $X \in \mathfrak{X}$ говорим верна ли гипотеза H_0 . Таким образом, статистический критерий может задаваться двумя множествами:

- $\mathfrak{X}_0 \subset \mathfrak{X}$ — принимается H_0 , \mathfrak{X}_0 называется областью принятия гипотезы;
- $\mathfrak{X}_1 = \mathfrak{X} \setminus \mathfrak{X}_0$ — принимается H_1 , \mathfrak{X}_1 называется критической областью.

Тогда $\mathfrak{X}_0 \sqcup \mathfrak{X}_1 = \mathfrak{X}$ и задача построения статистического критерия равносильна построению критического множества \mathfrak{X}_1 . В дальнейшем будем отождествлять понятие статистического критерия и критического множества.

Определение 9.8. Если $x \in \mathfrak{X}_0$, то говорят, что H_0 соглашается с данными или данные не противоречат гипотезе H_0 .

Определение 9.9. Если $x \in \mathfrak{X}_1$, то говорят, что данные противоречат гипотезе H_0 .

Рассмотрим возможные варианты:

	\mathfrak{X}_0	\mathfrak{X}_1
верна H_0	определили правильно	отвергаем истину
верна H_1	принимая ложь за истину	определили правильно

Очевидно ходим, чтобы вероятность $P(x \in \mathfrak{X}_1 | H_0)$ была как можно меньше. При построении критерия фиксируют некоторое малое значение α , которое называется уровнем значимости критерия, так, чтобы

$$P(x \in \mathfrak{X}_1 | H_0) \leq \alpha.$$

Если это неравенство выполняется, то говорят, что критерий \mathfrak{X}_1 имеет уровень значимости α и обозначается $\mathfrak{X}_{1,\alpha}$. При этом, очевидно, существуют различные критические области с одинаковым уровнем значимости.

В случае, когда H_0 и H_1 — простые гипотезы, вводятся понятия ошибок критерия. Критерий описывается вероятностями:

1. $P(X \in \mathfrak{X}_1 | H_0) = \alpha$ — ошибка 1 рода;
2. $P(X \in \mathfrak{X}_0 | H_1) = \beta$ — ошибка 2 рода.

Определение 9.10. Функцией мощности критерия W назовем функционал на множестве допустимых распределений \mathcal{F} и выборке X .

$$W(F_X) = W(F_X; \mathfrak{X}_{1,\alpha}) = P(X \in \mathfrak{X}_{1,\alpha} | F_X),$$

где $P(X \in \mathfrak{X}_{1,\alpha} | F_X)$ — вероятность попасть в $\mathfrak{X}_{1,\alpha}$, если F_X — истинное распределение.

Через функцию мощности критерия легко можно выразить вероятности ошибок первого и второго рода:

$$\alpha = W(F_X), \beta = 1 - W(F_X).$$

Аналогично уровень значимости определяется:

$$\alpha = \sup_{F \in \mathcal{F}_0} W(F).$$

Среди всех критериев с уровнем значимости α нас интересует наиболее мощный критерий, то есть тот, который минимизирует величину:

$$\beta = \sup_{F \in \mathcal{F}_1} (1 - W(F)).$$

Пример 9.11. Пусть \mathcal{F} состоит из двух распределений:

1. случайная величина принимает значение 0 с вероятностью p_0 и значение 1 с вероятностью p_1 ;
2. случайная величина принимает значение 1 с вероятностью q_1 и значение 2 с вероятностью q_2 .

При этом $p_1, q_1 \neq 0$, $p_1, q_1 \neq 1$, $p_0 + p_1 = 1 = q_1 + q_2$. В качестве основной гипотезы H_0 рассмотрим распределение Бернулли с вероятностью успеха p_1 .

Критическая область задается следующим образом:

$$\mathfrak{X}_1 = \{X_i = 1, \forall i = \overline{1, n}\}.$$

Иными словами: если есть хотя бы один 0, то выбираем гипотезу H_0 , иначе H_1 .

Тогда

$$\alpha = P\{H_1|H_0\} = p_1^n,$$

$$\beta = P\{H_0|H_1\} = 0.$$

Если же задать критическую область иначе:

$$\mathfrak{X}_1 = \{\exists i: X_i = 2\},$$

или принимаем \mathfrak{X}_1 , если есть хотя бы одна 2. В этом случае:

$$\alpha = P\{H_1|H_0\} = 0,$$

$$\beta = P\{H_0|H_1\} = q_1^n.$$

9.2 Проверка гипотезы о виде распределения

Рассмотрим задачу проверки гипотезы о виде распределения. Пусть дана выборка $X = (X_1 \dots X_n)$ из распределения $\mathcal{L}(\xi)$ и F_ξ - неизвестное распределение. Рассмотрим основную гипотезу $H_0: F_\xi = F(x)$, при этом никак не конкретизируем альтернативную гипотезу (H_1 — сложная гипотеза).

9.2.1 Критерий согласия Колмогорова

Критерий Колмогорова основан на теореме Колмогорова (см. 1.10). Статистика критерия определяется формулой:

$$D_n = D_n(X) = \sup_{x \in \mathbb{R}} \left| \widehat{F}_n(x) - F(x) \right|,$$

где D_n — это отклонение эмпирической функции распределения от теоретической функции распределения.

Мы знаем, что \widehat{F}_n является оптимальной, несмещенной и состоятельной оценкой для $F(x)$. Отсюда следует, что D_n не должно «сильно» отклоняться от 0.

По теореме Колмогорова для непрерывных функций распределения F и при $n \geq 20$:

$$P(\sqrt{n}D_n \geq \lambda_\alpha | H_0) = 1 - K(\lambda_\alpha) = \alpha.$$

При этом по значению α возможно однозначно определить величину λ_α .

Критерий формулируется следующим образом. Проверяем, выполняется ли неравенство: $\sqrt{n}D_n \geq \lambda_\alpha$, если да, то отвергаем гипотезу H_0 . Данному критерию соответствует критическая область

$$\mathfrak{X}_1 = \{ \bar{x} : D_n(\bar{x})\sqrt{n} \geq \lambda_\alpha \}.$$

Вместо статистики $\sqrt{n}D_n \geq \lambda_\alpha$ при малых значениях n ($n \geq 20$) рекомендуется использовать статистику

$$S_n = \frac{6nD_n + 1}{6\sqrt{n}}$$

(см. напр. [?]), которая также сходится к распределению Колмогорова.

Опишем способ вычисления значения $D_n = \sup_{x \in \mathbb{R}} \left| \widehat{F}_n(x) - F(x) \right|$. Вычисление супремума функции, вообще говоря, не является тривиальной задачей. Однако в виду того, что $\widehat{F}_n(x)$ принимает конечное число значений: $\{0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n}\}$, задача нахождения супремума функции сильно упрощается.

Пусть имеется вариационный ряд реализации выборки: $x_{(1)}, x_{(2)}, \dots, x_{(n)}$. Определим следующие две функции:

$$D_n^+ = \max_{1 \leq k \leq n} \left| \frac{k}{n} - F(x_{(k)}) \right|,$$

$$D_n^- = \max_{1 \leq k \leq n} \left| F(x_{(k)}) - \frac{k-1}{n} \right|.$$

Тогда вычислить значение D_n можно следующим образом:

$$D_n = \max\{D_n^-, D_n^+\}.$$

Однако критерий Колмогорова обладает рядом минусов:

1. Функция $D_n = \sup_{x \in R} |\hat{F}_n(x) - F(x)|$ не зависит от вида функции распределения $F(x)$, только в случае, когда $F(x)$ — непрерывная функция. Встает вопрос, что делать если $F(x)$ имеет точки разрыва.

Утверждение 9.12. Пусть Y_1, \dots, Y_n — независимые, одинаково распределенные случайные величины, $Y_i \sim \mathcal{R}[0,1]$, X_1, \dots, X_n — выборка из некоторого распределения, функция которого имеет точки разрыва. Построим следующую случайную величину:

$$U_i = F(X_i-) + Y_i[F(X_i) - F(X_i-)],$$

где $F(x_i-) = \lim_{z \downarrow 0} F(x_i - z)$. Тогда случайная величина $U_i \sim \mathcal{R}[0,1]$.

2. В случае сложных гипотез распределение $D_n(\theta)$, зависит как от вида априорных распределений, так и от способа получения оценок, размера выборки n , вида Θ . Существуют два подхода к проверке гипотезы о виде распределения в этом случае:
 - Для проверки гипотезы $H_0 : F_\xi(x) \in \mathcal{F}_0 = \{F_\theta(x), \theta \in \Theta\}$ сначала вычисляется оценка $\hat{\theta}$ неизвестных параметров. Имея оценку вычислить значение статистики Колмогорова K_n (или S_n). Критическую область определить по предвычисленным таблицам в зависимости от распределения, количества и вида параметров.
 - В случае достаточно большой выборки, можно разбить ее на две части: по одной получить оценки на неизвестные параметры, по второй проверить гипотезу о виде распределения.

Определение 9.13. Пусть случайные величины $\xi_1, \xi_2, \dots, \xi_n$ имеют стандартное нормальное распределение, тогда случайная величина:

$$\chi_n^2 = \sum_{i=1}^n \xi_i^2$$

имеет распределение, которое называется *распределением хи-квадрат с n степенями свободы*

Аналогичным образом определяется критерий Смирнова. Пусть дана выборка X_1, \dots, X_n .

$$D_{Sm}^+ = \sup_{x \in R} \left| \widehat{F}_n(x) - F(x) \right|,$$

$$D_{Sm}^- = -\inf_{x \in R} \left| \widehat{F}_n(x) - F(x) \right|.$$

$$Sm_n = \frac{(6nD_{S_n}^+ + 1)^2}{9n}.$$

Известно, что эта статистика имеет следующее распределение:

$$\mathcal{L}(S_m) = \chi_2^2.$$

Рассмотрим вопрос об оценке вероятности ошибки второго рода при применении критерия согласия Колмогорова. Обозначим функцию распределения, соответствующую гипотезе $H_0 - F_0(x)$, а функцию распределения, соответствующую альтернативной гипотезе, $F_1(x)$.

$$\beta = \mathbf{P} \left(\sqrt{n}D_n \leq \lambda_\alpha \mid H_1 \right) = \mathbf{P} \left(\sqrt{n} \sup_{x \in \mathbb{R}} \left| \widehat{F}_n(x) - F_0(x) \right| \leq \lambda_\alpha \mid H_1 \right)$$

Выберем некоторых x_0 . Для данного значения верно, что событие $\left\{ \sup_{x \in \mathbb{R}} \left| \widehat{F}_n(x) - F_0(x) \right| \leq a \right\} \subset \left\{ \left| \widehat{F}_n(x_0) - F(x_0) \right| \leq a \right\}$, соответственно верно

$$\begin{aligned} \beta &\leq \mathbf{P} \left(\sqrt{n} \left| \widehat{F}_n(x_0) - F(x_0) \right| \leq \lambda_\alpha \mid H_1 \right) = \\ &= \mathbf{P} \left(\sqrt{n} \left| \widehat{F}_{1n}(x_0) - F_0(x_0) \right| \leq \lambda_\alpha \right) = \\ &= \mathbf{P} \left(\sqrt{n} \frac{\left| \widehat{F}_{1n}(x_0) - F_0(x_0) - F_1(x_0) + F_1(x_0) \right|}{\sqrt{F_1(x_0)(1 - F_1(x_0))}} \leq \frac{\lambda_\alpha}{\sqrt{F_1(x_0)(1 - F_1(x_0))}} \right) = \\ &= \mathbf{P} \left(\frac{-\lambda_\alpha + \sqrt{n}(F_0(x_0) - F_1(x_0))}{\sqrt{F_1(x_0)(1 - F_1(x_0))}} \leq \right. \\ &\quad \left. \leq \sqrt{n} \frac{\widehat{F}_{1n}(x_0) - F_1(x_0)}{\sqrt{F_1(x_0)(1 - F_1(x_0))}} \leq \frac{\lambda_\alpha + \sqrt{n}(F_0(x_0) - F_1(x_0))}{\sqrt{F_1(x_0)(1 - F_1(x_0))}} \right) \approx \end{aligned}$$

$$\approx {}^1 \frac{1}{\sqrt{2\pi}} \int_{\frac{-\lambda\alpha + \sqrt{n}(F_0(x_0) - F_1(x_0))}{\sqrt{F_1(x_0)(1-F_1(x_0))}}}^{\frac{\lambda\alpha + \sqrt{n}(F_0(x_0) - F_1(x_0))}{\sqrt{F_1(x_0)(1-F_1(x_0))}}} e^{-\frac{t^2}{2}} dt$$

Несложно видеть, что с ростом n пределы интегрирования будут одновременно стремиться к бесконечности (к положительной или отрицательной зависит от знака разности $F_0(x_0) - F_1(x_0)$). То есть с ростом n значение интеграла будет стремиться к нулю, что свидетельствует о состоятельности критерия.

9.2.2 Критерий согласия хи-квадрат

Утверждение 9.14. Пусть $\bar{\xi}$ - случайный вектор $\bar{\xi} = (\xi_1, \dots, \xi_n)$, и $\xi_i \sim \mathcal{N}(0,1)$. И, вектор $\bar{\xi}$ имеет единичную матрицу ковариаций. Пусть также $\bar{c} = (c_1, c_2, \dots, c_n) \in \mathbb{R}^n$, такой что $|\bar{c}| = 1$.

Рассмотрим проекцию $\bar{\xi}^{(c)}$ на гиперплоскость $L_{\bar{c}} = \{x \in \mathbb{R}^n : (\bar{x}, \bar{c}) = 0\}$, которая ортогональна вектору \bar{c} . Тогда

- вектор $\bar{\xi}^{(c)}$ имеет математическое ожидание равное $\theta = (0, \dots, 0)$ и матрицу ковариации

$$C(\bar{\xi}^{(c)}) = E - \parallel c_i c_j \parallel_{i,j=1}^n,$$

- квадрат длины вектора $\bar{\xi}^{(c)}$ имеет распределение χ_{n-1}^2 (хи-квадрат с $n - 1$ степенью свободы)

Доказательство. Выпишем представление вектора $\bar{\xi}$ в исходном базисе:

$$\bar{\xi} = \bar{e}_1 \xi_1 + \dots + \bar{e}_{n-1} \xi_{n-1} + \bar{e}_n \xi_n.$$

Так как $|\bar{c}| = 1$ мы можем рассмотреть ортонормированный базис $\bar{e}'_1, \dots, \bar{e}'_{n-1}, \bar{e}'_n$, где $\bar{e}'_n = \bar{c}$:

$$\bar{\xi} = \bar{e}'_1 \xi'_1 + \dots + \bar{e}'_{n-1} \xi'_{n-1} + \bar{c} \xi'_n.$$

Из-за перехода от одного ортонормированного базиса к другому $\xi'_i \sim \mathcal{N}(0,1)$. Действительно, пусть матрица перехода от одного базиса к другому равна

¹Интегральная теорема Муавра-Лапласа для последовательности бернуллиевских случайных величин.

$A = \|a_{i,j}\|_{i,j=1}^n$. Тогда

$$M\xi'_i = M(a_{1,i}\xi_1 + \dots + a_{n,i}\xi_n) = 0.$$

Так как оба базиса ортонормированны, то $A \cdot A^T = E$. Найдем $D\xi'_i$:

$$D\xi'_i = D(a_{1,i}\xi_1 + \dots + a_{n,i}\xi_n) = \sum_{j=1}^n a_{j,i}^2 = 1.$$

Аналогично доказывается $\text{cov}(\xi'_i, \xi'_j) = 0$, $i \neq j$.

Выпишем проекцию вектора ξ на плоскость $L_{\bar{e}}$:

$$\bar{\xi}^c = \bar{e}'_1 \xi'_1 + \dots + \bar{e}'_{n-1} \xi'_{n-1} \bar{e}'_1 \xi'_1 + \dots + \bar{e}'_{n-1} \xi'_{n-1}$$

и рассмотрим квадрат длины проекции $\bar{\xi}^c$. Так как базис $\bar{e}'_1, \dots, \bar{e}'_{n-1}$ ортонормированный, получим следующее:

$$|\bar{\xi}^{(c)}|^2 = (\xi'_1)^2 + \dots + (\xi'_{n-1})^2,$$

то есть $|\bar{\xi}^{(c)}|^2$ имеет распределение хи-квадрат с $n - 1$ степенью свободы.

Очевидно, что

$$M(\bar{\xi}^{(c)}) = \bar{0}.$$

Найдем ковариационную матрицу:

$$C(\bar{\xi}) = C(\bar{\xi}^{(c)} + \xi'_n \bar{e}'_n) = C(\bar{\xi}^{(c)}) + C(\xi'_n \bar{e}'_n).$$

Найдем $C(\xi'_n \bar{e}'_n)$:

$$C(\xi'_n \bar{e}'_n) = C(\xi'_n \bar{e}) = \|\text{cov}(\xi'_n c_i, \xi'_n c_j)\|.$$

Учитывая то $\text{cov}(\xi'_i c_i, \xi'_j c_j) = c_i c_j$ получим:

$$C(\bar{\xi}^{(c)}) = E - \|c_i c_j\|_{i,j=1}^n.$$

□

Пусть ξ_1, \dots, ξ_n — независимые одинаково распределенные случайные величины, которые принимают значения $1, \dots, N$ с вероятностью p_1, \dots, p_n .

Введем случайную величину

$$\nu_k^{(n)} = \sum_{i=1}^n \text{Ind}(\xi_i = k).$$

Величину $\nu_k^{(n)}$ называют частотой встречаемости значения k . Определим случайный вектор частот, имеющий полиномиальное распределение:

$$\overline{\nu^{(n)}} = \left(\nu_1^{(n)}, \dots, \nu_N^{(n)} \right),$$

$$\mathbf{P} \left(\nu_i^{(n)} = m_i, i = \overline{1, N} \right) = \frac{n!}{m_1! \dots m_N!} p_1^{m_1} \dots p_N^{m_N}.$$

Рассмотрим следующую статистику:

$$X_N^2 = \sum_{i=1}^N \frac{\left(\nu_i^{(n)} - np_i \right)^2}{np_i} = \sum_{i=1}^N \frac{\left(\nu_i^{(n)} \right)^2}{np_i} - n,$$

которую будем называть статистикой Пирсона или статистика хи-квадрат.

Заметим, что $\frac{\nu_k^{(n)}}{n} \rightarrow p_k$ и значение статистики Пирсона должно стремиться к 0 при выборке из рассматриваемого распределения. Тогда критерий можно сформулировать следующим образом:

$$\mathfrak{X}_{1\alpha} = \{ X_N^2 \geq t_\alpha \}.$$

Остается вопрос о том, как правильно выбрать t_α .

Теорема 9.15 (Предельное распределение статистики Пирсона). *Пусть случайный вектор частот $\overline{\nu^{(n)}} = \left(\nu_1^{(n)}, \dots, \nu_N^{(n)} \right)$ имеет полиномиальное распределение с параметрами n и $\bar{p} = (p_1, \dots, p_N)$. Если вектор \bar{p} фиксирован, а $n \rightarrow \infty$, то распределение статистики Пирсона сходится к распределению χ^2 с $N - 1$ степенью свободы.*

Доказательство. Вектор частот $\overline{\nu^{(n)}} = \left(\nu_1^{(n)}, \dots, \nu_N^{(n)} \right)$ можно представить в виде суммы n независимых одинаково распределенных случайных векторов

$$\overline{\nu^{(n)}} = \sum_{t=1}^N (\text{Ind}\{\xi_t = 1\}, \dots, \text{Ind}\{\xi_t = n\}).$$

Математическое ожидание очевидно равно (p_1, \dots, p_N) , а матрица ковариаций равна

$$C(\overline{\nu^{(n)}}) = \text{diag}(p_1, \dots, p_N) - \|p_i p_j\|_{i,j=1}^N.$$

По этому согласно многомерной центральной предельной теореме распределение вектора

$$\left(\frac{\nu_1^{(n)} - np_1}{\sqrt{n}}, \dots, \frac{\nu_N^{(n)} - np_N}{\sqrt{n}} \right) \quad (5)$$

при $n \rightarrow \infty$ сходится к нормальному распределению с нулевым средним и матрицей ковариации $c(\overline{\nu^{(n)}})$. Статистику Пирсона можно интерпретировать как квадрат длины вектора

$$\left(\frac{\nu_1^{(n)} - np_1}{\sqrt{np_1}}, \dots, \frac{\nu_N^{(n)} - np_N}{\sqrt{np_N}} \right), \quad (6)$$

который получается из (5) линейным преобразованием: делением j -ой координаты на $\sqrt{p_j}$. При этом математическое ожидание останется нулевым, а в матрице ковариаций элемент i -ой строки и j -го столбца делится на $\sqrt{p_i p_j}$. Тогда распределение векторов (6) сходится к нормальному распределению с нулевым вектором средних и матрицей ковариаций

$$E - \|\sqrt{p_i p_j}\|.$$

Заметим, что для $\bar{c} = (\sqrt{p_1}, \dots, \sqrt{p_N})$ верно равенство:

$$\sum_{j=1}^N \frac{\nu_j^{(n)} - np_j}{\sqrt{np_j}} \cdot \sqrt{p_j} = 0.$$

Тогда распределение квадрата длины такого случайного вектора имеет распределение хи-квадрат с $N - 1$ степенью свободы. Поскольку квадрат длины — непрерывная функция, то распределение ее значения от допредельных векторов (6) сходится к распределению ее значений от случайного вектора. \square

На практике критерий хи-квадрат можно использовать для расчетов с хорошим приближением при $n \geq 50$ и $\nu_j \geq 5$, $j \in \overline{1, N}$.

Таким образом: гипотеза H_0 отвергается тогда и только тогда, когда $X_n^2 > \chi_{1-\alpha, N-1}^2$, где α — заданный уровень значимости.

Рассмотрим случай сложной гипотезы. Пусть гипотеза для полиномиального распределения имеет следующий вид:

$$H_0: \bar{p} = \bar{p}(\theta), \theta = (\theta_1, \dots, \theta_r), \theta \in \Theta, r < N - 1.$$

В этом случае при гипотезе H_0 вероятности исходов являются некоторыми функциями от параметра θ . Если выписать статистику Пирсона, то она будет зависеть от параметра θ . При фиксации некоторого θ мы можем вычислить статистику критерия хи-квадрат. Верна следующая

Теорема 9.16. Пусть $p_j(\theta)$, $j = \overline{1, N}$, $\theta = (\theta_1, \dots, \theta_r)$, при этом:

1. $\sum_{j=1}^N p_j(\theta) = 1, \forall \theta \in \Theta$,
2. $p_j(\theta) \geq c > 0, \forall j$
3. существуют непрерывные производные

$$\frac{\partial p_j(\theta)}{\partial \theta_k}, k = \overline{1, r},$$

$$\frac{\partial^2 p_j(\theta)}{\partial \theta_k \partial \theta_l}, k, l = \overline{1, r},$$

4. Матрица размера $N \times r$ $\left\| \frac{\partial^2 p_j(\theta)}{\partial \theta_k} \right\|$ имеет ранг r для всех $\theta \in \Theta$.

Пусть также

$$\hat{\theta} = \arg \max_{\theta} \prod_{j=1}^N (p_j(\theta))^{\nu_j},$$

Тогда статистика

$$\hat{X}_n^2 = X_n^2(\hat{\theta}) = \sum_{j=1}^N \frac{(\nu_j - np_j(\theta))^2}{np_j(\theta)}$$

имеет распределение хи-квадрат с $N - 1 - r$ степенями свободы.

В этом случае гипотеза H_0 отвергается тогда и только тогда, когда $\hat{X}_n^2 > \chi_{1-\alpha, N-1-r}^2$, где α — заданный уровень значимости.

!!!!!!!Добавить про состоятельность критерия хи-квадрат и близкие альтернативы

9.3 Гипотеза и критерии однородности

Пусть $X = (X_1 \dots X_n)$ из распределения $\mathcal{L}(\xi)$ с неизвестной функцией распределения $F_1(x)$ и $Y = (Y_1 \dots Y_n)$ из распределения $\mathcal{L}(\eta)$ также с неизвестной функцией распределения $F_2(x)$. Гипотеза однородности формулируется следующим образом $H_0 : F_1(x) = F_2(x)$ и заключается в проверке гипотезы о том, что рассматриваются две выборки из одного и того же распределения.

9.3.1 Критерий однородности Смирнова

Пусть X, Y - две выборки объема n и m соответственно \hat{F}_{1n} - э.ф.р., построенная по выборке X , \hat{F}_{2m} - э.ф.р., построенная по выборке Y . Рассмотрим статистику:

$$D_{n,m} = \sup_{x \in \mathbb{R}} \left| \hat{F}_{1n}(x) - \hat{F}_{2m}(x) \right|$$

В случае если F_1 и F_2 непрерывные функции распределения, то по теореме Смирнова статистика

$$\sqrt{\frac{n \cdot m}{n + m}} D_{n,m}$$

имеет распределение Колмогорова. Тогда критерий проверки гипотезы однородности можно сформулировать следующим образом: если $D_{n,m} > t_\alpha(n, m)$, то гипотезу H_0 отвергаем, где

$$t_\alpha(n, m) = \sqrt{\frac{1}{n} + \frac{1}{m}} t_\alpha, \quad K(t_\alpha) = 1 - \alpha.$$

При этом:

$$\mathbb{P} \left(D_{n,m} > \sqrt{\frac{1}{n} + \frac{1}{m}} t_\alpha \middle| H_0 \right) = \mathbb{P} \left(\sqrt{\frac{mn}{n+m}} D_{n,m} > t_\alpha \middle| H_0 \right) \underset{\substack{m \rightarrow \infty \\ n \rightarrow \infty}}{=} 1 - K(t_\alpha) = \alpha.$$

Данный критерий имеет ряд преимуществ:

1. Можем использовать статистику даже если не знаем вид распределения, кроме того, что оно **непрерывное**
2. $D_{n,m}$ считается легко

$$D_{n,m}^+ = \max_{1 \leq r \leq m} \left| \frac{r}{m} - \hat{F}_{1n}(Y_{(r)}) \right| = \max_{1 \leq r \leq n} \left| \hat{F}_{2m}(X_{(r)}) - \frac{r-1}{n} \right|$$

$$D_{n,m}^- = \max_{1 \leq r \leq m} \left| \widehat{F}_{1n}(Y_{(r)}) - \frac{r-1}{m} \right| = \max_{1 \leq r \leq n} \left| \frac{r}{n} - \widehat{F}_{2m}(X_{(r)}) \right|$$

$$D_{n,m} = \max \{ D_{n,m}^-, D_{n,m}^+ \}.$$

Однако применять мы его можем только в случае непрерывных распределений.

Стоит отметить, что сходимость к распределению Колмогорова достаточно медленная. В случае небольших значений n и m можно пользоваться таблицами, приведенными, например в [?].

9.3.2 Критерий однородности хи-квадрат

Рассмотрим критерий, который можно применить для проверки гипотезы однородности в случае, когда наблюдается некоторый переменный признак, принимающий конечное число $N \geq 2$ различных значений.

Как и для критерия однородности Пирсона изначально рассмотрим случай полиномиально распределенных случайных величин. Очевидным образом критерий обобщается на случай произвольных случайных величин. Очевидным плюсом данного критерия является тот факт, что с его помощью можно проверять однородность произвольного количества выборок. Пусть k — количество серий наблюдений $(X^{(1)}, X^{(2)}, \dots, X^{(k)})$. Каждая серия $X^{(i)}$ порождает вектор частот $\nu_i = (\nu_{i,1}, \dots, \nu_{i,N})$, $i = \overline{1, k}$. При этом для каждой выборки имеется свое вероятностное распределение $(p_{i1}, \dots, p_{iN}) = \bar{p}_i$, которое называется вероятностью появления *признаков*.

Гипотеза однородности H_0 заключается в том, что

$$\bar{p}_0 = \bar{p}_1 = \dots = \bar{p}_k = \bar{p},$$

где $\bar{p} = (p_1, \dots, p_N)$, $p_i > 0$, $i = \overline{1, N}$, $\sum_{i=1}^N p_i = 1$.

В случае верности гипотезы H_0 верно равенство: $M(\nu_{ij}|H_0) = n_i p_j$. Рассмотрим статистику

$$\sum_{i=1}^k X_k^2 = \sum_{i=1}^k \sum_{j=1}^N \frac{(\nu_{ij} - n_i p_j)^2}{n_i p_j}.$$

Как и в случае использования критерия хи-квадрат для случая сложной гипотезы заменим значения p_i их оценкой максимального правдоподобия \hat{p}_j ,

построенная по всем выборкам:

$$\widehat{p} = (\widehat{p}_1, \dots, \widehat{p}_N) = \arg \max_{\bar{p}} \prod_{i,j} p_j^{\nu_{i,j}} = \arg \max_{\bar{p}} \prod_j p_j^{\nu_{\cdot,j}},$$

где $\nu_{\cdot,j} = \sum_{i=1}^N \nu_{i,j}$. Отсюда легко можно заметить, что

$$\widehat{p}_j = \frac{\nu_{\cdot,j}}{n},$$

где $n = n_1 + \dots + n_k$. Получаем следующий вид критерия проверки однородности хи-квадрат:

$$\widehat{X}_{n_1, \dots, n_k}^2 = X_{n_1, \dots, n_k}^2(\widehat{p}) = n \sum_{i=1}^k \sum_{j=1}^N \frac{1}{n_i \nu_{\cdot,j}} \left(\nu_{i,j} - \frac{n_i \nu_{\cdot,j}}{n} \right)^2.$$

H_0 отвергаем тогда и только тогда, когда $X_{n_1, \dots, n_k}^2 > t_\alpha$.

Осталось узнать как считать величину t_α . Можно доказать, что $\mathcal{L}(X_{n_1, \dots, n_k}^2 | H_0) \xrightarrow{n_i \rightarrow \infty} \chi_{(k-1)(N-1)}^2$. Что дает нам следующий критерий проверки однородности: гипотезу H_0 отвергаем тогда и только тогда, когда $\widehat{X}_{n_1, \dots, n_k}^2 > \chi_{1-\alpha, (k-1)(N-1)}^2$, где α — заданный уровень значимости.

9.4 Выбор из двух простых гипотез. Критерий Неймана-Пирсона

Рассмотрим случай двух простых гипотез H_0 и H_1 . Иными словами, считаем, что допустимыми распределениями случайной величины ξ являются лишь два заранее заданных распределения $F_0(x)$ и $F_1(x)$. Необходимо по выборке $X = (X_1, \dots, X_n)$ из $\mathcal{L}(\xi)$ проверить гипотезу H_0 против альтернативы H_1 .

Выбор из двух простых гипотез можно представить в виде параметрической гипотезы. Действительно, пусть $\Theta = \{0,1\}$, и $F_\theta(x) = (1 - \theta)F_0(x) + \theta F_1(x)$.

В случае параметрических гипотез функцию мощности критерия можно переписать в виде:

$$W(\theta) = W(\theta; \mathfrak{X}_{1,\alpha}) = \mathbf{P}_\theta(X \in \mathfrak{X}_{1,\alpha}).$$

Сначала рассмотрим случай абсолютно непрерывных распределений. Для реализации выборки \bar{x} с помощью функции плотности можем выписать правдоподобие данных:

$$L(\bar{x}, \theta_i) = f_i(x_1) \cdot \dots \cdot f_i(x_n).$$

Как и ранее рассмотрим задачу нахождения такого статистического критерия, что при заданной ошибке 1 рода

$$\alpha = W(\theta_0; \mathfrak{X}_{1,\alpha}) = \int_{\mathfrak{X}_{1,\alpha}} L(\bar{x}; \theta_0) d\bar{x}$$

максимизировать функцию мощности

$$W(\theta_1; \mathfrak{X}_{1,\alpha}) = \int_{\mathfrak{X}_{1,\alpha}} L(\bar{x}; \theta_1) d\bar{x} = 1 - \beta \rightarrow \max,$$

где β — ошибка 2 рода. Параметрический критерий, минимизирующий ошибку 2 рода при заданной ошибке 1 рода называется *наиболее мощным критерием с уровнем значимости α* . Заметим, что функции $W(\theta_i; \mathfrak{X}_{1,\alpha})$ есть суть вероятности того, что выборка попадет в i -ю критическую область. Критическую область можно построить следующим образом: множество $\mathfrak{X}_{1,\alpha}$ состоит из таких \bar{x} , для которых правдоподобие $L(\bar{x}, \theta_1)$ будет больше правдоподобия $L(\bar{x}, \theta_0)$.

Определение 9.17. *Функция, имеющая вид:*

$$l(\bar{x}) = \frac{L(\bar{x}, \theta_1)}{L(\bar{x}, \theta_0)} = \frac{\prod_{i=1}^n f_1(x_i)}{\prod_{i=1}^n f_0(x_i)}$$

называется функцией отношения правдоподобия.

Выберем некоторую границу c . Если $l(\bar{x}) \geq c$, то принимаем H_1 , иначе — H_0 . Далее возьмем все $x \in X$ и упорядочим их по значению $l(\bar{x})$ и зададим такую c , чтобы выполнялось условие ошибка первого рода была в точности α .

Определение 9.18. *Назовем $T(X)$ тестовой статистикой, если выполняется равенство $T(\bar{x}) = l(\bar{x})$, и $l(\bar{x})$ — отношение правдоподобия.*

Определение 9.19. Критическим множеством критерия Неймана-Пирсона называется множество $\mathfrak{X}_{1,\alpha}^*$ имеющее вид:

$$\mathfrak{X}_{1,\alpha}^* = \{\bar{x} \in \mathfrak{X} : l(\bar{x}) \geq c_\alpha\},$$

где c_α такое, что ошибка 1 рода равна α .

Предположим далее, что $f_i(x) > 0$, так как из $f_i(x) = 0$ следует $L(x_i, \theta_0) = 0$, что говорит о верности другой гипотезы. Здесь и далее для сокращения записи вместо P_{θ_i} будем писать P_i . Определим вспомогательную функцию $\phi(c)$:

$$\phi(c) = P_0(l(\bar{x}) \geq c) = \int_{\bar{x}: l(\bar{x}) \geq c} L(\bar{x}, \theta_0) d\bar{x}.$$

Заметим, что при $c = 0$ функция принимает значение равное $\phi(0) = 1$. Покажем, что чем больше c , тем меньше значение $\phi(c)$:

$$1 \geq P_1(l(\bar{x}) \geq c) = \int_{\bar{x}: l(\bar{x}) \geq c} L(\bar{x}, \theta_1) d\bar{x} \geq c \cdot \int_{\bar{x}: l(\bar{x}) \geq c} L(\bar{x}, \theta_0) d\bar{x} = c \cdot \phi(c).$$

Следовательно:

$$\phi(c) \leq \frac{1}{c}.$$

Отсюда следует, что при $c \rightarrow \infty$ значение $\phi(c) \rightarrow 0$. Предположим, что $\phi(c)$ — непрерывная функция. Тогда для любого $\alpha \in (0; 1)$ можно найти такое $c_\alpha : \phi(c_\alpha) = \alpha$. Соответственно для множества $\mathfrak{X}_{1,\alpha}^* = \{\bar{x} : l(\bar{x}) \geq c_\alpha\}$ верно равенство:

$$W(\theta_0, \mathfrak{X}_{1,\alpha}^*) = P_0(\mathfrak{X}_{1,\alpha}^*) = \phi(c_\alpha) = \alpha.$$

Теорема 9.20 (Лемма Неймана-Пирсона). Пусть для фиксированного α существует такое c_α , что $\phi(c_\alpha) = \alpha$. Тогда критическая область $\mathfrak{X}_{1,\alpha}^* = \{\bar{x} : l(\bar{x}) \geq c_\alpha\}$ задает наиболее мощный критерий для гипотезы $H_0: F_\xi = F_0$ относительно альтернативы $H_1: F_\xi = F_1$ среди всех критериев с уровнем значимости α .

Доказательство. Пусть $\mathfrak{X}_{1,\alpha}$ — другая критическая область с уровнем значимости α :

$$W(\theta_0; \mathfrak{X}_{1,\alpha}) = P_0(\bar{x} \in \mathfrak{X}_{1,\alpha}) = \int_{\mathfrak{X}_{1,\alpha}} L(\bar{x}, \theta_0) d\bar{x} = \alpha.$$

Тогда

$$\begin{aligned} P_0(\mathfrak{X}_{1,\alpha} \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) &= P_0(\mathfrak{X}_{1,\alpha}) - P_0(\mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) = P_0(\mathfrak{X}_{1,\alpha}^*) - P_0(\mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) = \\ &= P_0(\mathfrak{X}_{1,\alpha}^* \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) \end{aligned}$$

Согласно определению множества $\mathfrak{X}_{1,\alpha}^*$, для любого \bar{x} не лежащего в нем, выполняется неравенство: $l(\bar{x}) < c_\alpha$ или

$$c_\alpha \cdot L(\bar{x}; \theta_0) > L(\bar{x}; \theta_1).$$

Следовательно,

$$\begin{aligned} P_1(\mathfrak{X}_{1,\alpha}^* \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) &\geq c_\alpha \cdot P_0(\mathfrak{X}_{1,\alpha}^* \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) = c_\alpha \cdot P_0(\mathfrak{X}_{1,\alpha} \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*) > \\ &> P_1(\mathfrak{X}_{1,\alpha} \setminus \mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*). \end{aligned}$$

Прибавив к обоим частям неравенства $P_1(\mathfrak{X}_{1,\alpha} \cap \mathfrak{X}_{1,\alpha}^*)$ получим:

$$W(\theta_1; \mathfrak{X}_{1,\alpha}^*) = P_1(\mathfrak{X}_{1,\alpha}^*) > P_1(\mathfrak{X}_{1,\alpha}) = W(\theta_1, \mathfrak{X}_{1,\alpha}).$$

□

Определение 9.21. Будем говорить, что статистический критерий является несмещенным, если $W(\theta) \geq \alpha$ для всех $\alpha \in \Theta_1$.

Утверждение 9.22. Критерий Неймана-Пирсона является несмещенным критерием.

Доказательство. 1) Рассмотрим случай $c_\alpha \geq 1$. Тогда

$$W(\theta_1, \mathfrak{X}_{1,\alpha}^*) = \int_{\mathfrak{X}_{1,\alpha}^*} L(\bar{x}, \theta_1) d\bar{x} \geq c_\alpha \cdot \int_{\mathfrak{X}_{1,\alpha}^*} L(\bar{x}, \theta_0) d\bar{x} \geq \alpha \cdot c_\alpha > \alpha$$

2) Рассмотрим случай $c_\alpha < 1$:

$$W(\theta_1, \mathfrak{X}_{1,\alpha}^*) = 1 - P(\overline{\mathfrak{X}_{1,\alpha}^*}) > 1 - c_\alpha P_0(\overline{\mathfrak{X}_{1,\alpha}^*}) \geq 1 - P_0(\overline{\mathfrak{X}_{1,\alpha}^*}) = \alpha$$

□

Пример 9.23. Пусть имеется выборка $X = (X_1, \dots, X_n)$ из распределения $\mathcal{L}(\xi)$. Рассмотрим две гипотезы:

$$H_0 : \xi \sim N(\theta_0, \sigma^2)$$

$$H_1 : \xi \sim N(\theta_1, \sigma^2)$$

Найдем функцию отношения правдоподобия:

$$\begin{aligned} l(\bar{x}) &= \frac{\prod_{i=1}^n f_1(x_i)}{\prod_{i=1}^n f_2(x_i)} = \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [(x_i - \theta_0)^2 - (x_i - \theta_1)^2] \right\} = \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \theta_0^2 - 2x_i\theta_0 - x_i^2 - \theta_1^2 + 2x_i\theta_1 \right\} = \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n \theta_0^2 - \theta_1^2 + 2x_i\theta_1 - 2x_i\theta_0 \right\} = \\ &= \exp \left\{ -\frac{n}{2\sigma^2}(\theta_0^2 - \theta_1^2) - \frac{n}{\sigma^2}(\theta_1 - \theta_0) \frac{1}{n} \sum_{i=1}^n x_i \right\} = \\ &= \exp \left\{ \frac{n}{\sigma^2}(\theta_0 - \theta_1) \bar{X} - \frac{n}{2\sigma^2}(\theta_0^2 - \theta_1^2) \right\} \geq c \end{aligned}$$

Прологарифмируем:

$$\frac{n}{\sigma^2}(\theta_0 - \theta_1) \bar{X} \geq \ln c + \frac{n}{2\sigma^2}(\theta_0^2 - \theta_1^2),$$

$$\bar{X} \geq \frac{\sigma^2}{n \cdot (\theta_0 - \theta_1)} \ln c + \frac{\theta_0 + \theta_1}{2}.$$

Получаем следующее эквивалентное равенство:

$$P_i(l(\bar{x}) \geq c_\alpha) = P_i(\bar{X} \geq t_\alpha).$$

Тогда:

$$\phi(c_\alpha) = P_0(\bar{X} \geq t_\alpha) = P_0\left(\frac{\sqrt{n}}{\sigma}(\bar{X} - \theta_0) \geq \frac{(t_\alpha - \theta_0)\sqrt{n}}{\sigma}\right) = \Phi\left(-\frac{(t_\alpha - \theta_0)\sqrt{n}}{\sigma}\right),$$

где Φ - функция стандартного нормального распределения.

Так как $\Phi(c)$ — непрерывная функция, то всегда найдем такое t_α . Тогда,

$$P_1(\bar{X} \geq t_\alpha) = P_1\left(\frac{\sqrt{n}}{\sigma}(\bar{X} - \theta_1) \geq \frac{\sqrt{n}(t_\alpha - \theta_1)}{\sigma}\right) = \Phi\left(-\frac{\sqrt{n}(t_\alpha - \theta_1)}{\sigma}\right).$$

Точное вычисление параметров критерия возможен в том случае, когда распределение статистики $l(X)$ (или эквивалентной ей как в примере выше) известно как при гипотезе H_0 , так и при альтернативе H_1 . Это не всегда возможно. В случае большого объема выборки ($n \rightarrow \infty$) возможно рассмотреть асимптотический подход, основанный на центральной предельной теореме. При логарифмировании функции отношения правдоподобия мы получаем сумму одинаково распределенных независимых величин вида

$$Z_i = \ln \frac{f_1(X_i)}{f_0(X_i)}, i \in \overline{1, n}.$$

Из $l(\bar{X}) \geq c_\alpha$ следует, что $S_n \geq \ln c_\alpha$, где $S_n = \sum_{i=1}^n Z_i$. Воспользуемся центральной предельной теоремой (если это возможно) и получим предельное распределение статистики $\ln l(\bar{X})$:

Если $S_n \sim N(\mu_0, \sigma_0^2)$, то принимаем гипотезу H_0 ;
 Если $S_n \sim N(\mu_1, \sigma_1^2)$, то принимаем гипотезу H_1 ,

где

$$\mu_i = M_{\theta_i} Z_1, \sigma_i^2 = D_{\theta_i} Z_1, i = \overline{1, 2}.$$

В этом случае ошибку первого рода можно вычислить по формуле:

$$\alpha = P_0(S_n \geq \ln c_\alpha) = P_0\left(\frac{S_n - n\mu_0}{\sqrt{n}\sigma_0} \geq \frac{\ln c_\alpha - n\mu_0}{\sqrt{n}\sigma_0}\right),$$

а ошибку второго рода:

$$\beta = P_1(S_n < \ln c_\alpha) = P_1\left(\frac{S_n - n\mu_1}{\sqrt{n}\sigma_1} < \frac{\ln c_\alpha - n\mu_1}{\sqrt{n}\sigma_1}\right).$$

Рассмотрим вопрос применения Критерия Неймана-Пирсона в случае дискретных распределений.

Можно провести аналогичные рассуждения, как и в случае с непрерывными распределениями. Пусть как и ранее $f_j(z_k) > 0$, для всех z_k — возможных значений случайной величины ξ , и для $j = \overline{0, 1}$. То есть для рассматриваемых гипотез вероятность любого из возможных значений случайной величины ξ , распределение которой мы хотим установить, ненулевая.

Общий принцип остаётся прежним: рассматриваем статистику отношения правдоподобия $l(\bar{x})$. Все $x \in \mathfrak{X}$ «упорядочиваем» в соответствии с величиной

значения функции отношения правдоподобия:

$$l(\bar{x}) = \frac{L(\bar{x}, \theta_1)}{L(\bar{x}, \theta_0)}.$$

В критическое множество \mathfrak{X}_1 включим максимальное число этих x , так, чтобы выполнялось неравенство:

$$\sum_{\bar{x} \in \mathfrak{X}_1} L(\bar{x}; \theta_0) \leq \alpha.$$

Однако в отличие от непрерывного случая здесь не всегда можно получить равенство величине α в силу дискретности распределения.

Пусть $\dots l_k < l_{k+1} < \dots$ — возможные значения статистики $l(\bar{x})$. Могут возникнуть две ситуации:

1. Существует $l_k \in \mathbb{N}$ такой, что верно равенство:

$$\sum_{\bar{x}: l(\bar{x}) \geq l_k} L(\bar{x}; \theta_0) = \alpha.$$

В этом случае критерий не отличается от непрерывного случая и применяется аналогично, то есть: H_0 отвергается тогда и только тогда, когда $l(\bar{x}) \in \mathfrak{X}_{1\alpha}^*$, $\mathfrak{X}_{1\alpha}^* = \{\bar{x}: l(\bar{x}) \geq l_k\}$ — наиболее мощный критерий (н.м.к.) при альтернативе H_1 среди всех критериев уровня значимости α .

2. При заданном уровне α можно определить такое $k = k(\alpha)$, что

$$\sum_{\bar{x}: l(\bar{x}) \geq l_{k+1}} L(\bar{x}; \theta_0) < \alpha < \sum_{\bar{x}: l(\bar{x}) \geq l_k} L(\bar{x}; \theta_0).$$

Иначе говоря, обозначив

$$\sum_{\bar{x}: l(\bar{x}) \geq l_{k+1}} L(\bar{x}; \theta_j) = \alpha_j, \quad j = \overline{0, 1},$$

$$p_j = P(l(\bar{x}) = l_k) = \sum_{\bar{x}: l(\bar{x}) = l_k} L(\bar{x}; \theta_j), \quad j = \overline{0, 1}$$

получаем:

$$\alpha_0 < \alpha < \alpha_0 + p_0.$$

Рассмотрим более подробно второй случай. Как в этом случае построить критерий с уровнем значимости α ? Можно предложить два решения:

- Перейти от α_0 к $\alpha_0 + p_0$ и получить 1 случай, для которого все доказано. Но в этом случае точность уровня значимости может быть низкой.
- Рассмотрим случайную величину

$$\xi \sim \text{Bin} \left(1, \frac{\alpha - \alpha_0}{p_0} \right).$$

Предложим следующее правило принятия решения:

$$\varphi^*(\bar{x}) = \begin{cases} 1, & \text{если } l(\bar{x}) > l_k \\ \xi, & \text{если } l(\bar{x}) = l_k \\ 0, & \text{если } l(\bar{x}) < l_k \end{cases}$$

То есть если $l(\bar{x}) > l_k$ — отвергаем гипотезу H_0 , $l(\bar{x}) < l_k$ — принимаем гипотезу H_0 . Если же $l(\bar{x}) = l_k$ бросаем монетку с вероятностью 1 (орел) равной $\frac{\alpha - \alpha_0}{p_0}$. Если выпала единица, то отвергаем H_0 , иначе — принимаем. Такое правило называют *рандомизированным критерием*.

Покажем, что рандомизированный критерий является критерием с уровнем значимости α . Действительно,

$$\begin{aligned} P(H_1|H_0) &= P_0(\varphi^*(X) = 1) = \\ &= P_0(l(X) > l_k) + \frac{\alpha - \alpha_0}{p_0} P_0(l(X) = l_k) = \alpha_0 + \frac{\alpha - \alpha_0}{p_0} p_0 = \alpha. \end{aligned}$$

Его мощность вычисляется аналогично:

$$W(\theta_1; \varphi^*) = P_1(l(X) > l_k) + \frac{\alpha - \alpha_0}{p_0} P_1(l(X) = l_k) = \alpha_1 + \frac{\alpha - \alpha_0}{p_0} p_1.$$

Покажем, что φ^* - наиболее мощный критерий с уровнем значимости α . Рассмотрим другой (произвольный) критерий φ с уровнем значимости α :

$$\varphi: P_0(\varphi(X) = 1) = \alpha.$$

Представим выборочное пространство в следующем виде:

$$\mathfrak{X} = \mathfrak{X}^+ \bigcup \mathfrak{X}^0 \bigcup \mathfrak{X}^-,$$

где

- $\mathfrak{X}^+ = \{\bar{x} : \varphi^*(\bar{x}) - \varphi(\bar{x}) > 0\},$
- $\mathfrak{X}^- = \{\bar{x} : \varphi^*(\bar{x}) - \varphi(\bar{x}) < 0\},$
- $\mathfrak{X}^0 = \{\bar{x} : \varphi^*(\bar{x}) = \varphi(\bar{x}) = 0\}.$

Если $\bar{x} \in \mathfrak{X}^+$, то $\varphi^*(x) > 0$. Тогда

$$\frac{L(\bar{x}; \theta_1)}{L(\bar{x}; \theta_0)} \geq l_k$$

и $L(\bar{x}; \theta_1) \geq l_k L(\bar{x}; \theta_0)$. Аналогично, если $\bar{x} \in \mathfrak{X}^-$, то $\varphi_1^*(\bar{x}) < 1$ и $L(\bar{x}; \theta_1) \leq l_k L(\bar{x}; \theta_0)$.

Таким образом:

$$\sum_{\bar{x}} (\varphi^*(\bar{x}) - \varphi(\bar{x})) (L(\bar{x}; \theta_1) - l_k L(\bar{x}; \theta_0)) = \sum_{\bar{x} \in \mathfrak{X}^+} + \sum_{\bar{x} \in \mathfrak{X}^-} \geq 0.$$

Отсюда для разности мощностей получаем:

$$\begin{aligned} W(\theta_1; \varphi^*) - W(\theta_1; \varphi) &= \mathbf{P}_1(\varphi^*(X) = 1) - \mathbf{P}_1(\varphi(X) = 1) = \\ &= \sum_{\bar{x}} (\varphi^*(\bar{x}) - \varphi(\bar{x})) L(\bar{x}; \theta_1) \geq \\ &\geq l_k \sum_{\bar{x}} (\varphi^*(\bar{x}) - \varphi(\bar{x})) L(\bar{x}; \theta_0) = l_k (\mathbf{P}_0(\varphi^*(X) = 1) - \mathbf{P}_0(\varphi(X) = 1)) \geq 0. \end{aligned}$$

То есть, $W(\theta_1; \varphi^*) \geq W(\theta_1; \varphi)$. Из этого следует, что φ^* — наиболее мощный критерий.

Пример 9.24. Пусть о неизвестной вероятности успеха в бернулиевской модели $\text{Bin}(1, \theta)$ имеются две простые гипотезы:

- $H_0: \theta = \theta_0;$
- $H_1: \theta = \theta_1, \theta_1 \geq \theta_0.$

Такие критерии зачастую называют односторонними и обозначают H_1^+ .

Выпишем функцию правдоподобия:

$$L(\bar{x}; \theta_j) = (\theta_j)^r (1 - \theta_j)^{n-r},$$

где $r = r(\bar{x}) = \sum_{i=1}^n x_i$ — наблюдавшееся число «успехов».

Рассмотрим функцию отношения правдоподобия:

$$l(\bar{x}) = \left(\frac{\theta_1(1 - \theta_0)}{\theta_0(1 - \theta_1)} \right)^r \left(\frac{(1 - \theta_1)}{(1 - \theta_0)} \right)^n.$$

Функция $f(x) = x/(1 - x)$ возрастает на интервале $(0, 1)$, поэтому, при $\theta_1 > \theta_0$ $f(\theta_1)/f(\theta_0) > 1$ и неравенство $l(\bar{x}) \geq c$ эквивалентно неравенству

$$r(\bar{x}) \geq \frac{\ln c - n\rho_1}{\rho},$$

где

$$\rho_1 = \ln \left(\frac{1 - \theta_1}{1 - \theta_0} \right), \quad \rho = \ln \left(\frac{\theta_0(1 - \theta_1)}{\theta_1(1 - \theta_0)} \right).$$

Следовательно критическая область критерия Неймана-Пирсона выражается через статистику $r(\bar{x})$ и имеет вид:

$$\mathfrak{X}_{1\alpha}^* = \{\bar{x} : r(\bar{x}) \geq r_\alpha\}.$$

Так как статистика $r(\bar{x})$ при верности гипотезы H_j имеет распределение $\text{Bin}(n, \theta_j)$, то легко вычисляем ошибки первого и второго рода. При этом ошибка первого рода не зависит от альтернативы. От нее зависит только ошибка второго рода.

Заметим, что в случае $n \rightarrow \infty$ можем воспользоваться ЦПТ и рассчитать ошибки критерия пользуясь нормальным приближением.

10 Сложные гипотезы

Случай, когда основная и альтернативная гипотезы являются простыми — достаточно редки. Рассмотрим пример, в котором основная гипотеза $H_0 : F_\theta, \theta \in \Theta$ — простая гипотеза (один параметр), а гипотеза $H_1 : F_{\theta_2}, \theta_2 \in \Theta \setminus \theta$ (альтернативная) — сложная гипотеза.

Определение 10.1. Семейство распределений $\{F_\theta, \theta \in \Theta\}$ называется семейством с монотонным отношением правдоподобия, если существует такая достаточная статистика $T(\bar{x})$ такая, что:

$$l(\bar{x}) = \frac{f_{\theta_1}(\bar{x})}{f_{\theta_0}(\bar{x})}$$

является монотонной функцией от $T(\bar{x})$

Пользуясь критерием факторизации получим, что если $T(\bar{x})$ — достаточная статистика, то

$$L(\bar{x}; \theta) = g(T(\bar{x}); \theta) \cdot h(\bar{x})$$

и

$$l(\bar{x}) = \frac{g(T(\bar{x}), \theta_1)h(\bar{x})}{g(T(\bar{x}), \theta_0)h(\bar{x})}.$$

Функция $l(\bar{x})$ должна монотонно возрастать (убывать) по $T(\bar{x})$.

Теорема 10.2. Пусть семейство распределений $\{F_\theta, \theta \in \Theta\}$ имеет монотонное отношение правдоподобия. Тогда в классе всех критериев проверки простой гипотезы $H_0 = \theta$ против сложной альтернативы $H_1 = \theta_1 > \theta$ с уровнем значимости α существует равномерно наиболее мощный критерий, задаваемый функцией:

$$\varphi^*(x) = \begin{cases} 1 & \text{если } T(\bar{x}) > c \\ \xi & \text{если } T(\bar{x}) = c \\ 0 & \text{если } T(\bar{x}) < c \end{cases}$$

где c и p определяются по формуле:

$$P_0(T(\bar{x}) > c) + pP_0(T(\bar{x}) \geq c) = \alpha.$$

Доказательство. Пусть отношение

$$\frac{g(T(\bar{x}); \theta_1)}{g(T(\bar{x}); \theta_0)}$$

возрастает по T . Построим критерий Неймана-Пирсона в задаче (H_0, H_1) . В данном случае:

$$l(\bar{x}) \geq c \Leftrightarrow T(\bar{x}) \geq c_\alpha^+$$

причем граница c_α^+ определяется лишь распределением

$$F(x; \theta_0) = P_{\theta_0}\{T(\bar{x}) \geq c_\alpha^+\} = \alpha.$$

Таким образом, критерий $\mathfrak{X}_{1\alpha}^{*+} = \{T(\bar{x}) \geq c_{\alpha}^{+}\}$ не зависит от конкретной альтернативы $\theta_1 > \theta_0$, следовательно, он есть р.н.м.к. для задачи $(\theta_0; \theta_1)$.

Если же

$$\frac{g(T(\bar{x}); \theta_1)}{g(T(\bar{x}); \theta_0)}$$

убывает по T , то неравенство для T заменяется на противоположное. Аналогично рассматривается и случай для левосторонней H_1^- . \square

Пример 10.3. Рассмотрим экспоненциальное семейство:

$$f(x; \theta) = \exp\{A(\theta)B(x) + C(\theta) + D(x)\}.$$

Достаточной статистикой в этом случае является: $T(\bar{x}) = \sum_{i=1}^n B(X_i)$. Действительно:

$$l(\bar{x}) = \exp\{(A(\theta) - A(\theta_0)) \sum B(\bar{x}) + n(c(\theta) - c(\theta_0))\}.$$

Если A — монотонная функция, то и $l(\bar{x})$ — монотонная функция. В этом случае существует Р.Н.М.К.